



**UNIVERSIDADE FEDERAL DO VALE DO SÃO
FRANCISCO**
**CURSO DE GRADUAÇÃO EM ENGENHARIA DE
COMPUTAÇÃO**

DANIELE SILVA REIS

**DETERMINAÇÃO DE SÓLIDOS SOLÚVEIS TOTAIS EM
MANGAS PALMER ATRAVÉS DE PROCESSAMENTO
DIGITAL DE IMAGENS**

**JUAZEIRO - BA
2019**

DANIELE SILVA REIS

**DETERMINAÇÃO DE SÓLIDOS SOLÚVEIS TOTAIS EM
MANGAS PALMER ATRAVÉS DE PROCESSAMENTO
DIGITAL DE IMAGENS**

Trabalho apresentado à Universidade Federal do Vale do São Francisco - UnivASF, Campus Juazeiro, como requisito da obtenção do título de Bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Rosalvo Ferreira de Oliveira Neto

Co-Orientadora: M. Sc.^a Josenara Daiane de Souza Costa

JUAZEIRO - BA
2019

ESTA SERÁ SUA FICHA CATALOGRÁFICA

ESTA SERÁ SUA FOLHA DE APROVAÇÃO

RESUMO

Um dos atributos mais significativos para a garantia da qualidade de uma fruta é a quantidade de açúcares nela contida. Entretanto, para a obtenção deste valor, é exigida a destruição da amostra, de forma que seu conteúdo seja analisado. Essa abordagem, além de destrutiva, é onerosa; assim, o emprego de um sistema de visão computacional para previsão desta variável de saída mostra-se vantajoso. Entretanto, é necessário definir as variáveis visuais da fruta a partir das quais o teor de sólidos solúveis será obtido. Assim, foi conduzido um estudo baseado em diferentes artigos onde é empregado o processamento de imagens para predição de atributos de qualidade. A fruta analisada foi a manga, da variedade ‘Palmer’, por ser produzida em abundância no Vale do São Francisco e por contribuir para a economia de Juazeiro (BA) e Petrolina (PE) através de sua exportação. As melhores técnicas de pré-processamento e inferência também foram avaliadas, de forma a obter a melhor abordagem para predição de sólidos solúveis em manga. Foi encontrado que as melhores técnicas de pré-processamento foram filtro da mediana, operações de abertura e fechamento e limiarização simples. Os atributos visuais mais significantes foram a dimensão de correlação, taxa R/B e as médias do canal B na região equatorial e da haste. O coeficiente de correlação foi igual a 0,9752, obtido através da *Random Forest*.

Palavras-chave: Quantidade de açúcares. Visão computacional. *Random Forest*.

ABSTRACT

One of the most significant attributes for guaranteeing the quality of a fruit is the amount of sugars contained in it. However, to obtain this value, the destruction of the sample is required, so that its content is analyzed. This approach, besides being destructive, is onerous; thus, the use of a computer vision system to predict this output variable is advantageous. However, it's necessary to define the fruit's visual variables from which the sugar content will be obtained. Thus, the study was conducted based on different articles in which image processing is employed to predict quality attributes. The analyzed fruit was the mango, from 'Palmer' variety, due to its abundant production in the São Francisco Valley and its contribution to the economy in Juazeiro (BA) and Petrolina (PE) through exportation. The best pre-processing and inference techniques were also evaluated in order to obtain the best approach to predict sugars in mangoes. It was found that the best pre-processing techniques were median filter, opening and closing operations and thresholding. The most significant visual aspects were the correlation dimension, R/B rate and the B channel mean in the stalk and apex regions. The correlation coefficient was equal to 0,9752 and was obtained through Random Forest.

Key-words: *Sugar content. Computer vision. Random Forest.*

LISTA DE ILUSTRAÇÕES

Figura 1 – Subespaço de cores RGB.	16
Figura 2 – Representação 3D do espaço de cores HSV.	17
Figura 3 – Remoção de ruído <i>salt and pepper</i> por um filtro da mediana com tamanho da janela igual a 3x3.	18
Figura 4 – Utilização da erosão e dilatação em uma imagem (a) Imagem original (b) Imagem erodida (c) Imagem dilatada.	19
Figura 5 – Operações morfológicas aplicadas na letra "j"(a) Abertura (b) Fechamento. .	19
Figura 6 – Limiarização simples aplicada em uma imagem, com <i>threshold</i> igual a 127. À esquerda, a imagem gradiente, cuja intensidade varia entre 0 e 255. À direita, o resultado da limiarização.	20
Figura 7 – Segmentação de Otsu. À esquerda, a imagem original. À direita, a imagem segmentada pelo algoritmo.	21
Figura 8 – Etapas empregadas pelos autores.	24
Figura 9 – Imagem pré-processada e segmentada de uma manga, com suas regiões marcadas.	25
Figura 10 – Pré-processamento das imagens, extração de seus atributos e posterior construção dos modelos LS-SVM.	27
Figura 11 – Extração de atributos realizada pelos autores.	28
Figura 12 – Processo de obtenção da imagem final a partir de rotações da manga. .	30
Figura 13 – Mangas da variedade Sala ⁵ em diferentes estádios de maturação.	32
Figura 14 – Etapas do estudo, desde a coleta das frutas até a validação dos modelos. .	38
Figura 15 – Câmara para aquisição das imagens.	39
Figura 16 – Fotos tiradas da manga Palmer (a) 35 dias após a floração (b) 50 dias após a floração (c) 65 dias após a floração (d) 80 dias após a floração (e) (f) 95 dias após a floração (g) 110 dias após a floração (h) 125 dias após a floração (i) 140 dias após a floração (j) 155 dias após a floração (k) 170 dias após a floração (l) 10 dias após a colheita (m) 20 dias após a colheita.	40
Figura 17 – Antes e depois da filtragem por filtro da mediana (a) Imagem original (b) Imagem tratada pelo filtro da mediana.	41
Figura 18 – Segmentação e operação de abertura na imagem (a) Imagem segmentada (b) Imagem tratada pela operação de abertura.	41
Figura 19 – Limiarização simples e operação de fechamento na imagem (a) Imagem limiarizada (b) Imagem tratada pela operação de fechamento.	42
Figura 20 – Imagem pré-processada resultante.	42
Figura 21 – Variação do SST conforme a matiz.	45

Figura 22 – Modelos de Regressão linear construídos para o atributo matiz (a) Presente estudo (b) Trabalho de Khairunniza-Bejo e Kamarudin (2011).	46
Figura 23 – Resultados obtidos para a matiz (a) Coeficiente de correlação (R) (b) RMSE.	46
Figura 24 – Variação do SST conforme as variáveis RGB (a) Canal R (b) Canal G (c) Canal B.	47
Figura 25 – Resultados obtidos para as variáveis RGB (a) Coeficiente de correlação (R) (b) RMSE.	48
Figura 26 – Atributos mais importantes para a determinação de SST.	49
Figura 27 – Representação de uma foto no canal R/B.	50
Figura 28 – Regiões equatorial e haste em uma manga representada no canal B.	50
Figura 29 – Variação dos atributos mais importantes para o modelo conforme o SST (a) Taxa R/B (b) Dimensão de correlação (c) Média B na região equatorial (d) Média B na região da haste.	51

LISTA DE TABELAS

Tabela 1 – Regras <i>fuzzy</i> adotadas por Pandey, Gamit e Naik (2014) para classificação de mangas quanto a seu tamanho.	33
Tabela 2 – Atributos-alvo determinados pelos autores.	35
Tabela 3 – Atributos extraídos pelos autores.	35
Tabela 4 – Técnicas de inferência utilizadas nos trabalhos estudados.	36
Tabela 5 – Métricas empregadas pelos autores.	36
Tabela 6 – Estatística descritivas dos valores de referência dos sólidos solúveis totais.	45
Tabela 7 – Valores de R e RMSE obtidos pela <i>Random Forest</i> e MLR com todas as variáveis.	48
Tabela 8 – <i>Strings</i> de busca pesquisadas e artigos encontrados.	60

LISTA DE ABREVIATURAS E SIGLAS

BCD	Dimensão de contagem de caixa – <i>Box Counting Dimension</i>
CCD	Dispositivo de carga acoplada – <i>Charge-coupled Device</i>
CD	Dimensão de correlação – <i>Correlation Dimension</i>
DD	Dimensão de dilatação – <i>Dilation Dimension</i>
LS-SVM	Máquina de vetores de suporte por mínimos quadrados – <i>Least-Squares Support Vector Machine</i>
MDA	Análise discriminante múltipla – <i>Multiple Discriminant Analysis</i>
MLR	Regressão linear múltipla – <i>Multiple Linear Regression</i>
PCA	Análise de componentes principais – <i>Principal Component Analysis</i>
RBF	Função de base radial – <i>Radial Basis Function</i>
RMSE	Raiz do erro quadrático médio – <i>Root Mean Square Error</i>
RFE	Eliminação recursiva de atributos - <i>Recursive Feature Elimination</i>
RNA	Rede neural artificial
RPI	<i>Ripening Index</i>
RSS	Soma do quadrado dos resíduos – <i>Residual Sum of Squares</i>
SST	Sólidos solúveis totais
SVM	Máquina de vetores de suporte – <i>Support Vector Machine</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	MOTIVAÇÃO	13
1.2	DEFINIÇÃO DO PROBLEMA	13
1.3	OBJETIVOS	13
1.3.1	Objetivo Geral	13
1.3.2	Objetivos específicos	14
1.4	ORGANIZAÇÃO DO TRABALHO	14
2	FUNDAMENTAÇÃO TEÓRICA	15
2.1	BACKGROUND	15
2.1.1	Espaços de cores	15
2.1.1.1	RGB	15
2.1.1.2	$L^*a^*b^*$	16
2.1.1.3	HSV	16
2.1.2	Pré-processamento de imagens	17
2.1.2.1	Filtro da mediana	18
2.1.2.2	Operações de abertura e fechamento (<i>Opening and closing operations</i>)	18
2.1.3	Segmentação de imagens	19
2.1.3.1	Limiarização	19
2.1.3.2	Segmentação de Otsu	20
2.1.4	Técnicas de inferência	21
2.1.4.1	Régressão linear múltipla	22
2.1.4.2	<i>Random Forest</i>	22
2.1.5	Avaliação do desempenho de modelos	23
2.2	TRABALHOS RELACIONADOS	23
2.2.1	Síntese dos trabalhos estudados	35
3	MATERIAL E MÉTODOS	37
3.1	COLETA DAS AMOSTRAS	38
3.2	AQUISIÇÃO DAS IMAGENS	38
3.3	OBTENÇÃO DOS VALORES DE REFERÊNCIA	40
3.4	PRÉ-PROCESSAMENTO	40
3.5	EXTRAÇÃO DE VARIÁVEIS	43
3.6	CONSTRUÇÃO E VALIDAÇÃO DOS MODELOS	43
4	RESULTADOS E DISCUSSÃO	45
4.1	MODELO COM TODAS AS VARIÁVEIS	48
5	CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS	52

5.1	TRABALHOS FUTUROS	52
6	REFERÊNCIAS	53
ANEXO A <i>Strings</i> de busca empregadas		60

1 INTRODUÇÃO

O Nordeste é uma das regiões de destaque na produção de manga, particularmente nas áreas irrigadas do semiárido, que apresentam boas condições para o desenvolvimento desta fruta (EMBRAPA SEMIÁRIDO, 2010). Em 2015, a região foi responsável por 70% das áreas colhidas, na qual a Bahia e Pernambuco foram os maiores contribuidores, alcançando as duas primeiras colocações na produção de manga dentre os demais estados (ANUÁRIO BRASILEIRO DE FRUTICULTURA, 2017). Na Bahia e Pernambuco, destacam-se as cidades de Juazeiro (BA) e Petrolina (PE), localizadas no Vale do São Francisco. No ano de 2016, elas foram responsáveis por quase 30% da produção nacional (PAM, 2017) e por 89% da exportação de manga no ano de 2014 (BRANCO, 2016).

Para a manutenção da demanda por mangas do Vale do São Francisco, é necessário prezar pela qualidade do produto, sendo este um fator crucial considerado pelo consumidor no momento da compra. Dentre os atributos determinantes para a qualidade da manga, destaca-se sua docura (SANTOS NETO et al., 2017). Este atributo é representado pelos sólidos solúveis totais (SST), que representam o conteúdo total de açúcares na fruta (SCHMUTZLER; HUCK, 2016). Entretanto, este atributo é normalmente obtido através de um refratômetro¹, que quantifica os SST contido no suco extraído, o que exige a destruição das amostras no processo, impossibilitando a comercialização das mesmas. Assim, surge a necessidade de determinar este atributo através de uma metodologia que não destrua as amostras.

Neste contexto, destaca-se a visão computacional, subárea da Inteligência Artificial que dá aos computadores a capacidade de aprendizado e inferência com base em informações visuais (GONZALEZ; WOODS, 2009). Em um sistema desse tipo as imagens digitais são manipuladas através de processamento de imagens, visando a extração de informações significativas sobre as mesmas. Assim, o teor de SST em mangas pode ser obtido a partir das fotos tiradas das frutas, através de um modelo preditivo que relate este teor com as informações visuais extraídas da manga. Um sistema de visão computacional, além de eliminar a necessidade da destruição das amostras, pode possibilitar a determinação do atributo desejado de forma rápida e precisa.

¹Instrumento óptico utilizado para determinar o índice de refração de uma substância (FERRAZ, 2015). Ele pode ser utilizado para monitorar a concentração de açúcar em uma solução, retornando um valor em °Brix, que corresponde a um grama de açúcar (sacarose) por 100g da solução.

1.1 MOTIVAÇÃO

O trabalho proposto possui potencial para beneficiar a comercialização da manga ao viabilizar a automatização de processos manuais. Assim, a determinação da qualidade das frutas torna-se mais rápida, econômica e consistente (DONIS-GONZÁLEZ et al., 2013). Como a obtenção do teor de sólidos solúveis não exige a destruição das amostras, produtoras e/ou consumidores de mangas não teriam mais o prejuízo do descarte, além de poderem proporcionar ao mercado consumidor um produto com qualidade assegurada.

1.2 DEFINIÇÃO DO PROBLEMA

Para a obtenção de uma informação desejada a partir de uma imagem, é necessário cumprir uma sequência de etapas que se inicia na aquisição das imagens das amostras. Segundo Esquef (2002), após a aquisição é realizado o pré-processamento das imagens. Esta etapa é fundamental em um sistema de visão computacional, sendo necessária para remover informações indesejadas, realçar ou atenuar algumas das partes da imagem. Após ser realizado o pré-processamento, é aplicada a segmentação, para que a imagem seja dividida em partes disjuntas, visando sua simplificação (JOSEPH; SINGH, 2014). No contexto deste trabalho, a única região de interesse é a manga; assim, as imagens foram segmentadas visando a separação entre a fruta e o plano de fundo. A penúltima etapa realizada foi a extração de atributos, em que para cada imagem é obtido um conjunto de características que a define. Por fim, estes atributos de cada imagem foram relacionados ao atributo desejado através de um modelo preditivo.

Entretanto, a escolha de técnicas de pré-processamento de imagens e atributos empregados não é realizada de forma trivial e depende da natureza do problema. Logo, para a construção de um bom modelo preditivo de sólidos solúveis totais (SST), diferentes técnicas de pré-processamento foram testadas e, para a determinação dos atributos mais significativos, um estudo investigativo sobre elas foi conduzido. Por fim, a relação entre os atributos e o SST deverá ser modelada através de uma Regressão linear e Random Forest, cujos desempenhos foram avaliados através de métricas apropriadas. Assim, através deste estudo se buscou um profundo entendimento entre os aspectos visuais da manga e sua docura.

1.3 OBJETIVOS

1.3.1 Objetivo Geral

O objetivo geral do trabalho consiste na identificação de quais atributos de uma imagem da manga devem ser considerados para a predição dos sólidos solúveis.

1.3.2 Objetivos específicos

- Determinar as técnicas de pré-processamento de imagens mais adequadas para o problema;
- Realizar um estudo investigativo quanto aos atributos através de modelos de Regressão linear e Random Forest;

1.4 ORGANIZAÇÃO DO TRABALHO

O trabalho possui, além da Introdução, os capítulos de Fundamentação teórica, Material e métodos, Resultados e Discussão e Considerações finais e Trabalhos futuros. Na fundamentação é discorrido sobre todos os tópicos necessários para o entendimento do trabalho e os artigos selecionados para o estudo. No capítulo de Material e métodos, é explicada a metodologia a ser aplicada, desde a coleta das mangas até a construção dos modelos preditivos. Os resultados obtidos no trabalho são mostrados no capítulo seguinte e, por fim, no último capítulo é feita uma conclusão sobre o estudo conduzido, assim como potenciais trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 BACKGROUND

Para um entendimento apropriado do estudo investigativo, são discutidos aqui conceitos básicos do processamento digital de imagens, como espaços de cores, pré-processamento e técnicas de inferência para determinação de um atributo desejado.

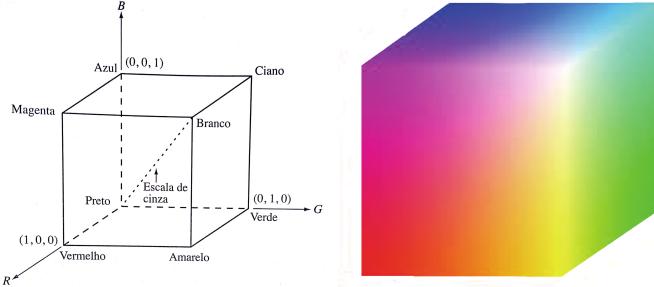
2.1.1 Espaços de cores

Um espaço de cores é um modelo matemático utilizado para a representação de uma cor através de três ou mais componentes (SHAIK et al., 2015). Um espaço de cor pode ser orientado a um hardware específico, como o modelo RGB (*Red, Green, Blue*), para exibição em monitores coloridos ou aquisição por uma câmera digital. Entretanto, este espaço de cor não permite uma interpretação humana exata de como a cor é composta. Por outro lado, espaços de cores como o L*a*b* e HSV (*Hue, Saturation, Value*) permitem uma descrição mais natural.

2.1.1.1 RGB

Este modelo é baseado nas três cores primárias, a partir das quais ele é nomeado: vermelho (*Red*), verde (*Green*) e azul (*Blue*). Ele é representado por um sistema de coordenadas 3D, em que cada cor é dada por um vetor que se origina na origem. Os três elementos do vetor consistem nas intensidades de cada cor primária, e assim, uma imagem RGB é representada por três matrizes, cada uma contendo as intensidades do respectivo canal (R, G, B) para todos os pixels da imagem. Quando as três cores são combinadas em suas intensidades máximas, o olho humano percebe a cor resultante como branca. Por outro lado, quando as três intensidades são nulas, tem-se a cor preta como resultante. No subespaço RGB, mostrado na Figura 1, o segmento de reta que une as cores branca e preta consiste na escala de cinza, onde as intensidades dos três canais são iguais. Os demais vértices do cubo correspondem às cores primárias e secundárias (SONKA; HLAVAC; BOYLE, 2014).

Figura 1 – Subespaço de cores RGB.



Fonte: (GONZALEZ; WOODS, 2009; DATAR; JONES; SMITH JR., 2005).

2.1.1.2 L*a*b*

Este espaço de cores, também chamado de CIE-Lab, emprega como componentes a luminosidade (L^*), que varia entre 0 (preto) e 100 (branco) e os canais “vermelho-verde” (a^*) e “amarelo-azul” (b^*). Estes últimos canais representam a variação da cor entre verde até vermelho e amarelo até azul respectivamente. A representação de uma imagem neste sistema de cores é obtida a partir da conversão do espaço RGB para o XYZ inicialmente, através da equação (2.1):

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} 0,4125 & 0,3576 & 0,1804 \\ 0,2127 & 0,7152 & 0,0722 \\ 0,0193 & 0,1192 & 0,9502 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (2.1)$$

Após essa conversão, os valores L^* , a^* e b^* são obtidos a partir das equações (2.2), (2.3) e (2.4) (KAUR; KRANTHI, 2012), em que (X_b, Y_b, Z_b) é a coordenada que representa a cor branca neste espaço de cor.

$$L^* = \begin{cases} 116 * (\frac{Y}{Y_b})^{\frac{1}{3}} - 16 & \text{onde } \frac{Y}{Y_b} > 0,008856 \\ 903,3 & \text{onde } \frac{Y}{Y_b} \leq 0,008856 \end{cases} \quad (2.2)$$

$$a^* = 500 * \left[\frac{X_b^{\frac{1}{3}}}{X_b} - \frac{Y_b^{\frac{1}{3}}}{Y_b} \right] \quad (2.3)$$

$$b^* = 200 * \left[\frac{X_b^{\frac{1}{3}}}{X_b} - \frac{Z_b^{\frac{1}{3}}}{Z_b} \right] \quad (2.4)$$

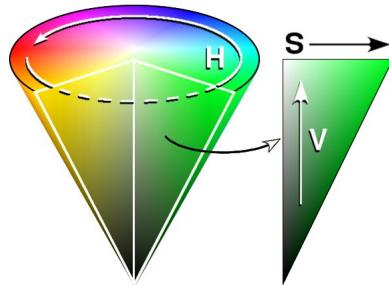
2.1.1.3 HSV

O sistema HSV, também conhecido como HSB, possui como componentes a matiz (*Hue*), saturação (*Saturation*) e valor ou brilho (*Value* ou *Brightness*), sendo capaz de

descrever uma cor de uma forma mais intuitiva para os humanos (NADAFZADEH; MEHDIZADEH; SOLTANIKAZEMI, 2018).

A matiz é associada à cor dominante em uma mistura de cores, da forma como é percebida por um humano. Ela é descrita em graus, variando entre 0° e 360° , de acordo com sua localização na roda de cores, conforme a Figura 2. A saturação mede o grau de diluição de uma cor pura por luz branca, sendo estimada de acordo com a distância da cor até a origem do cone, que representa a cor branca. Por fim, o valor ou brilho indica a quantidade de luz na combinação, sendo obtida a partir da distância da cor a partir do preto até o branco. Tanto a saturação quanto o valor/brilho possuem valores variando entre 0 e 1 (DORJ; LEE; YUN, 2017).

Figura 2 – Representação 3D do espaço de cores HSV.



Fonte: (Wikipedia, 2019).

Pode ser realizada a conversão de uma imagem no espaço de cores RGB para HSV, de forma a se obter uma melhor descrição da mesma, através das seguintes equações:

$$H = \begin{cases} \theta, & \text{se } B \leq G \\ 360 - \theta, & \text{se } B > G \end{cases} \quad (2.5)$$

$$\theta = \arccos \left\{ \frac{\frac{1}{2}[(R - G) + (R - B)]}{\sqrt{[(R - G)^2 + (R - G) * (G - B)]}} \right\} \quad (2.6)$$

$$S = 1 - \frac{3}{R + G + B} [\min(R, G, B)] \quad (2.7)$$

$$V = \frac{1}{3}(R + G + B) \quad (2.8)$$

2.1.2 Pré-processamento de imagens

A seguir estão descritas algumas das técnicas de pré-processamento mais comuns. Elas subdividem-se quanto ao domínio em que atuam, podendo ser realizadas no domínio

espacial, em que as técnicas são aplicadas nos pixels diretamente, ou no domínio da frequência, em que os métodos são realizados no espectro de frequência da imagem (BEDI; KHANDELWAL, 2013).

2.1.2.1 Filtro da mediana

A filtragem da mediana consiste em uma operação não linear realizada no domínio espacial. Através dela o ruído de uma imagem é removido enquanto as bordas são preservadas, pois ele não é tão sensível a valores extremos. Para realizar a filtragem, move-se uma janela de tamanho predefinido pixel a pixel, de forma que cada valor seja substituído pela mediana dos valores dos pixels contidos na janela (HEMALATHA; SUMATHI, 2016). Este filtro é comumente empregado para imagens com ruído do tipo *salt and pepper*, que consiste em pixels aleatórios de cor branca ou preta, conforme mostra a Figura 3.

Figura 3 – Remoção de ruído *salt and pepper* por um filtro da mediana com tamanho da janela igual a 3x3.



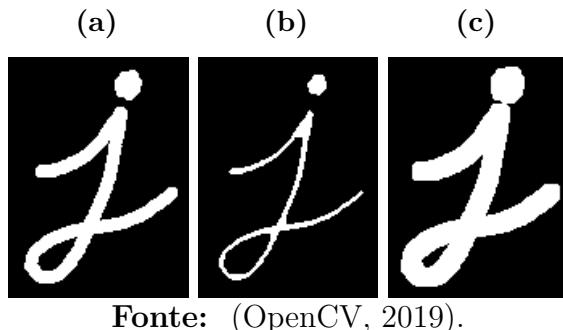
Fonte: (MathWorks Inc., 2006).

2.1.2.2 Operações de abertura e fechamento (*Opening and closing operations*)

As operações de abertura e fechamento são do tipo morfológicas, em que são realizadas transformações em uma imagem, normalmente binária, com base no formato do objeto nela contido. Elas se diferem quanto à ordem em que as operações de erosão e dilatação, também morfológicas, são realizadas em uma imagem.

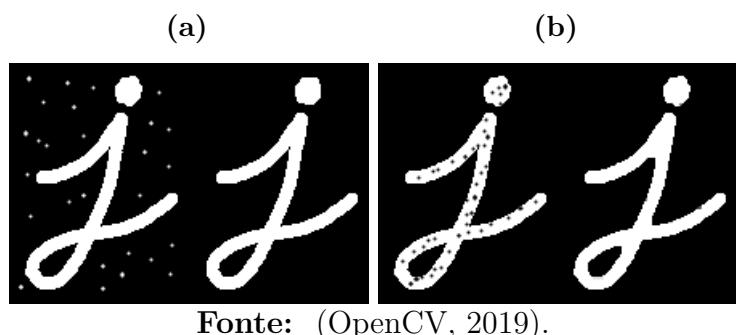
Nestas duas operações, um *kernel*, que consiste em uma janela de tamanho predefinido preenchida com 0s ou 1s, percorre a imagem original, substituindo o valor de um pixel caso os pixels contidos na janela sejam todos iguais a 1, no caso da erosão, ou pelo menos um deles seja igual a 1, no caso da dilatação. Na Figura 4 são mostrados os efeitos do uso da erosão e dilatação em uma mesma imagem.

Figura 4 – Utilização da erosão e dilatação em uma imagem (a) Imagem original (b) Imagem erodida (c) Imagem dilatada.



A operação de abertura realiza a erosão seguida de dilatação, resultando na eliminação de ruídos pontuais enquanto mantém as formas do objeto. Por outro lado, a operação de fechamento primeiro aplica a dilatação e depois a erosão, o que, além de também manter o contorno do objeto, contribui para o preenchimento de pequenos buracos (ARCO et al; 2015). A Figura 5 mostra o resultado da utilização destas operações.

Figura 5 – Operações morfológicas aplicadas na letra "j"(a) Abertura (b) Fechamento.



2.1.3 Segmentação de imagens

O objetivo da segmentação consiste em dividir a imagem em subconjuntos disjuntos, de forma a obter apenas a região desejada. A segmentação torna-se simples quando na imagem em questão há objetos contrastantes em um fundo uniforme. Dessa forma, pode-se utilizar uma abordagem baseada no histograma da imagem, que fornece a frequência dos níveis de intensidade dela (GONZALEZ; WOODS, 2009).

2.1.3.1 Limiarização

A limiarização é o método de segmentação mais simples, rápido e pouco custoso existente. Ela é utilizada em imagens em que os objetos nela presentes possuem uma absorção de luz uniforme ao longo de suas superfícies, de forma que, a partir de um valor

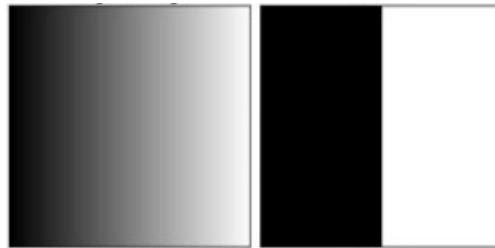
limiar, ou *threshold*, é possível fazer a separação completa dos objetos da imagem (SONKA; HLAVAC; BOYLE, 2008).

Assim, dada uma imagem $f(i, j)$, obtém-se uma imagem segmentada $g(i, j)$ conforme a equação abaixo, considerando um *threshold* T dado:

$$g(i, j) = \begin{cases} 1, & \text{se } f(i, j) \geq T, \\ 0, & \text{se } f(i, j) < T \end{cases} \quad (2.9)$$

Na Figura 6 é mostrado o resultado da limiarização simples aplicada numa imagem gradiente em escala de cinza. Como esta imagem é representada em 8 bits e seus valores de intensidade variam entre 0 e 255 (2^8), ao utilizar um limiar igual a 127, a imagem resultante consiste em duas metades cujos pixels são iguais a 0 e 1.

Figura 6 – Limiarização simples aplicada em uma imagem, com *threshold* igual a 127. À esquerda, a imagem gradiente, cuja intensidade varia entre 0 e 255. À direita, o resultado da limiarização.



Fonte: (OpenCV, 2003).

2.1.3.2 Segmentação de Otsu

Esta técnica de segmentação é eficaz para imagens bimodais, cujos histogramas possuem dois picos. Este método calcula um limiar ótimo que se localiza aproximadamente no meio dos dois picos (GONZALEZ; WOODS, 2009). O algoritmo de Otsu busca um *threshold* t tal que a variância entre uma mesma classe é minimizada. No contexto de uma imagem, uma classe seria o objeto de estudo ou o plano de fundo. A função a ser minimizada é dada por:

$$\sigma_w^2(t) = q_1(t)\sigma_1^2(t) + q_2(t)\sigma_2^2(t) \quad (2.10)$$

Em que $q_1(t)$ e $q_2(t)$ são as probabilidades das classes associadas ao limiar t, dadas por:

$$q_1(t) = \sum_{i=1}^t P(i) \quad q_2(t) = \sum_{i=t+1}^I P(i) \quad (2.11)$$

Em que $P(i)$ é o histograma da imagem, tratado como função de densidade de probabilidade, e I é o nível máximo de intensidade da imagem. $\sigma_1^2(t)$ e $\sigma_2^2(t)$ são as variâncias das classes, dadas por:

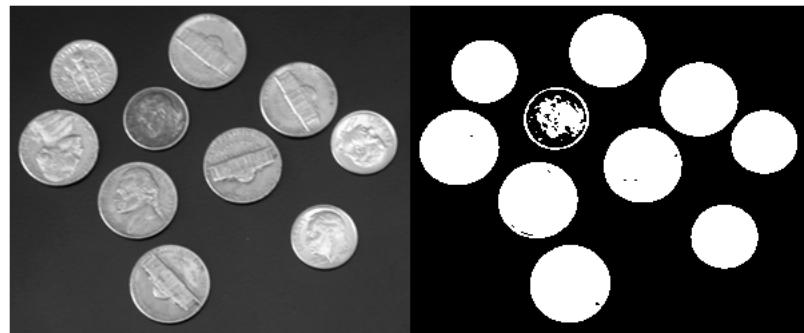
$$\sigma_1^2(t) = \sum_{i=1}^t [i - \mu_1(t)]^2 \frac{P(i)}{q_i(t)} \quad \sigma_2^2(t) = \sum_{i=t+1}^I [i - \mu_1(t)]^2 \frac{P(i)}{q_2(t)} \quad (2.12)$$

Em que:

$$\mu_1(t) = \sum_{i=1}^t i \frac{P(i)}{q_i(t)} \quad \mu_2(t) = \sum_{i=t+1}^I i \frac{P(i)}{q_2(t)} \quad (2.13)$$

Na Figura 7 é mostrada uma imagem original e o resultado da segmentação de Otsu.

Figura 7 – Segmentação de Otsu. À esquerda, a imagem original. À direita, a imagem segmentada pelo algoritmo.



Fonte: (Mathworks Inc., 2006).

2.1.4 Técnicas de inferência

As técnicas aqui apresentadas são empregadas para a predição de uma variável de saída desejada com base nas variáveis de entrada fornecidas, através de modelos supervisionados de regressão ou classificação, em que a variável de saída é quantitativa ou qualitativa, respectivamente (DA SILVA; PERES; BOSCAROLI, 2017). Para tal, deve-se utilizar um conjunto de amostras de treinamento, em que as variáveis de entrada e saída são conhecidas, para a construção de um modelo matemático que extraia padrões a partir dos dados fornecidos. Assim, tendo modelado o relacionamento entre as variáveis, pode-se realizar a predição para novas amostras, em que sua variável de saída é desconhecida (GAMA, 2015).

2.1.4.1 Regressão linear múltipla

A MLR (*Multiple Linear Regression*) é um método de regressão que assume um relacionamento linear entre os atributos de entrada e o de saída (JAMES et al., 2013). Ela é uma extensão da regressão simples, que emprega apenas uma variável de entrada, e apresenta um bom desempenho quando empregada em um conjunto de dados que não possua ruído ou colinearidade entre os atributos. A equação que descreve a MLR é dada por:

$$Y = \beta_0 + \beta_1 X + \epsilon \quad (2.14)$$

Em que Y é o vetor de atributo alvo, β_0 é o intercepto, β_1 é o vetor de inclinações da equação, X é o vetor de atributos e ϵ é o erro aleatório.

Os parâmetros da MLR são normalmente estimados pelo método dos mínimos quadrados, que busca minimizar a soma do quadrado dos resíduos (RSS – *Residual Sum of Squares*), dada pela equação abaixo:

$$RSS = e_1^2 + e_2^2 + \dots + e_n^2 \quad (2.15)$$

Em que $e_1^2, e_2^2, \dots, e_n^2$ correspondem à diferença entre o valor previsto pelo modelo e o valor real para as n amostras.

2.1.4.2 Random Forest

A *Random Forest* consiste em uma técnica *ensemble* não linear, em que uma variável qualitativa ou quantitativa é determinada através de uma combinação de modelos de árvores de decisão (FRIEDMAN; HASTIE; TIBSHIRANI, 2001). A relação entre as variáveis de entrada e a de saída é modelada através de um conjunto de regras de decisão, construídas por divisões binárias e recursivas dos dados de treinamento. Cada regra de decisão utiliza uma única variável de entrada para a divisão dos dados, sendo ela selecionada a partir de um subconjunto aleatório de todas as variáveis. Um modelo de regressão é então construído a partir das variáveis selecionadas e o erro RSS é calculado (HUTENGS; VOHLAND, 2016). As regras de decisão e consequentemente as variáveis de entrada, são selecionadas visando a minimização desse erro. Assim, a *Random Forest* permite a determinação das variáveis mais significativas para a predição da variável de saída.

O valor previsto resultante será a média dos resultados obtidos para cada árvore de decisão. Para evitar a correlação entre as árvores, elas são construídas a partir de subconjuntos não disjuntos dos dados de entrada, o que torna o modelo resultante mais estável, robusto e preciso (BREIMAN, 2001).

2.1.5 Avaliação do desempenho de modelos

Para a avaliação da capacidade preditiva dos modelos, é comumente utilizada a estratégia de validação cruzada *k-fold* (*k-fold cross validation*). Ela é empregada para assegurar que não há um sobreajuste (*overfitting*) no modelo, através da divisão do conjunto de dados em *k* subconjuntos disjuntos, com uma alocação das amostras para o conjunto de treinamento ou teste (DA SILVA; PERES; BOSCAROLI, 2017). Assim, um dos subconjuntos é utilizado como teste e os *k*-1 demais para o treinamento, de forma que o modelo realize a predição para dados desconhecidos. Este procedimento é repetido *k* vezes, alterando os subconjuntos a cada vez.

As predições resultantes podem então ser avaliadas através de métricas, tais como o coeficiente de correlação e RMSE, empregadas nos artigos em que a regressão foi realizada. Estes indicadores medem, respectivamente, o grau de dependência entre as variáveis de entrada e saída e a magnitude média dos erros estimados (ALVES; VECCHIA, 2011), conforme as equações abaixo:

$$R = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.16)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.17)$$

Em que x_i é o valor da variável de entrada, \bar{x} é a média dos valores de x , y_i é o valor real da variável de saída, \bar{y} é a média dos valores de y , n é o número de amostras e \hat{y}_i é o valor previsto para a variável de saída.

2.2 TRABALHOS RELACIONADOS

A seguir são discutidos dez artigos (*Apêndice A*) em que é empregado o processamento digital de imagens para determinação de atributos de qualidade em mangas. O estudo investigativo foi conduzido de acordo com as técnicas e métricas empregadas pelos autores, assim como os atributos extraídos das imagens das mangas.

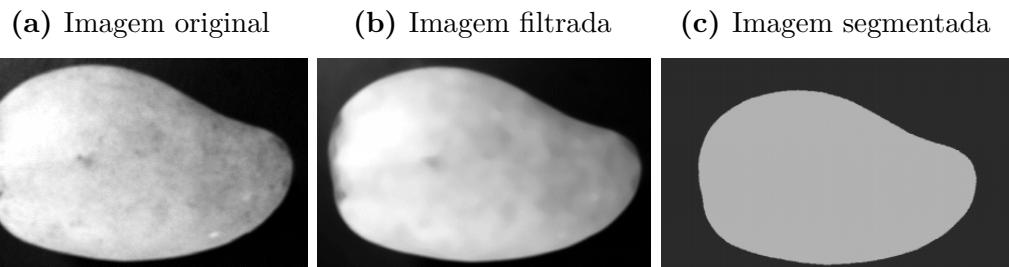
Teoh e Syaifudin (2007) propuseram em seu trabalho a determinação do peso de mangas da variedade Chokanan² através de imagens obtidas por uma câmera digital. 100 amostras aleatórias de mangas maduras e verdes foram coletadas e divididas entre treinamento e teste (50 para cada conjunto). Os valores reais do peso das mangas foram obtidos por uma balança digital. As mangas foram inicialmente imersas em água e limpas

²Variedade originária da Tailândia, caracterizada por frutos compridos com pontas cônicas, polpa sem fibra, pele grossa e alta resistência a doenças.

usando uma esponja e, após isso, foram postas em uma superfície preta e tiveram suas imagens tiradas por uma câmera de 0.3m mm/pixel de resolução, que foi situada a 22 cm acima do fruto, com uma fonte de luz de cada lado do aparelho.

Para o pré-processamento das imagens, inicialmente empregou-se o filtro da mediana de tamanho 15x15 para correção de inconsistências nas imagens devido à iluminação não uniforme. As imagens foram então segmentadas por limiarização, através da análise do histograma bimodal. A Figura 8 mostra os resultados das etapas empregadas pelos autores. A partir da imagem binária foi contado o número de pixels da região da manga, de forma que através desta variável independente o peso da respectiva manga fosse determinado. Um modelo de regressão linear foi então construído utilizando para tal 50 amostras de manga, enquanto que as demais foram empregadas para o teste do modelo, por intervalos de confiança a 95%. A abordagem proposta pelos autores mostrou-se precisa, alcançando um coeficiente de correlação igual a 97,69% e erro médio igual a 3,76%.

Figura 8 – Etapas empregadas pelos autores.



Fonte: (TEOH; SYAIFUDIN, 2007).

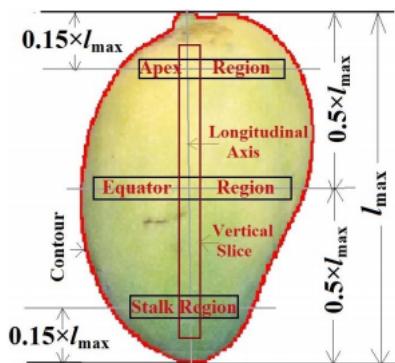
No estudo de Nandi, Tudu e Koley (2014), mangas de diferentes variedades foram separadas quanto aos dias restantes até o apodrecimento das mesmas. Foram obtidas 1350 amostras de cinco diferentes variedades e provenientes de três pomares, coletadas em três lotes com um intervalo de uma semana entre eles, sendo que em cada lote havia 90 mangas de cada variedade. As mangas foram utilizadas como entrada no sistema automatizado até o dia do apodrecimento delas, resultando em 16400 imagens. Em cada dia, três especialistas determinaram os dias restantes até a data de expiração. As imagens tiradas foram divididas em quatro grupos quanto aos dias restantes até que a respectiva manga apodrecesse (12 dias restantes, 9 até 12 dias, 5 até 8 dias e 1 até 4 dias).

Para a classificação automática das mangas, foi desenvolvido um sistema composto por uma correia transportadora, motor, válvulas solenoides, controladora lógica, câmara de aquisição de imagens e um computador. Uma câmera com Dispositivo de Carga Acoplada (CCD, *Charge-coupled Device*) com resolução 640x480 e frame rate igual a 30 frames/s foi posicionada no interior da câmara, iluminada artificialmente, sendo que as imagens foram enviadas ao computador pela porta USB. As mangas eram dispostas na correia transportadora, de forma que, através de válvulas solenoides, elas fossem posicionadas no

recipiente relativo à classe prevista.

Inicialmente os frames adequados foram pré-processados por um filtro *deblurring* de Wiener e filtro da mediana. Após isso, foram convertidos para uma imagem binária e as bordas foram traçadas por um algoritmo baseado em código em cadeia. As imagens das mangas foram então alinhadas em posição vertical para a posterior extração dos atributos. Os autores utilizaram apenas o espaço RGB para tal, levando em consideração o processo de maturação da manga e seu efeito nas regiões da fruta. Assim, as variáveis escolhidas foram as médias dos valores R, G e B da manga inteira e das três regiões (cume, equatorial e haste ou *apex*, *equator* e *stalk*), o gradiente dos três canais ao longo do eixo longitudinal, diferença das médias R, G e B da manga inteira e das três regiões. A Figura 9 exibe as regiões da manga consideradas para a extração de atributos.

Figura 9 – Imagem pré-processada e segmentada de uma manga, com suas regiões marcadas.



Fonte: (NANDI; TUDU; KOLEY, 2014).

O melhor subconjunto de variáveis foi obtido por eliminação recursiva de atributo (RFE) aliada à SVM, onde se obteve um *ranking* para cada variável. A SVM foi computada iterativamente, incrementando uma variável por vez, obtida a partir de uma lista decrescente de *ranking*. A classificação foi realizada por um ensemble de 7 SVMs binárias, em que cada uma realizava a separação de uma combinação diferente de 2 classes. Os parâmetros ótimos das SVMs e o melhor *kernel* foram obtidos por validação cruzada 6-fold através de uma busca em *grid*. Após a classificação ser feita, o computador comunica-se com o controlador lógico que ativa a válvula correspondente à classe prevista e controla a velocidade da correia transportadora.

O sistema proposto pelos autores apresentou resultados satisfatórios, alcançando uma acurácia média igual a 96% ao empregar a SVM Gaussian RBF, sendo que o subconjunto de variáveis obtido pelo método RFE continha predominantemente atributos derivados do canal R.

Zheng e Lu (2012) propuseram um método para classificação de mangas quanto a seu estágio de escurecimento empregando a LS-SVM. As 90 mangas coletadas de um supermercado possuíam diferentes graus de escurecimento. Elas foram classificadas visualmente por um perito em três diferentes classes: fresca sem escurecimento, escurecimento moderado e escurecimento severo. Foram então tiradas três imagens de cada manga através de uma câmera digital Canon EOS 50 D, sob iluminação solar. Antes da extração dos atributos, cada imagem foi pré-processada através da sua subtração pelo fundo.

Os atributos extraídos foram os valores médios dos canais L*, a*, b*, e as dimensões fractais dos frutos, que consistem em descritores geométricos das imagens. Estas foram calculadas por três diferentes técnicas: dimensão de contagem de caixa (BCD, *Box Counting Dimension*), dimensão de correlação (CD, *Correlation Dimension*) e dimensão de dilatação (DD, *Dilation Dimension*).

Na técnica BCD, o espaço euclidiano que contém a imagem é dividido em um *grid* de caixas de tamanho r , que, ao ser diminuído progressivamente, resulta em diferentes quantidades de caixas não vazias, dada por $N(r)$. O valor da variável BCD é então dado por:

$$BCD = \lim_{r \rightarrow 0} \frac{\log N(r)}{\log(1/r)} \quad (2.18)$$

De forma semelhante, na variável DD cada pixel da borda da imagem é substituído por um círculo de diâmetro r que aumenta progressivamente, resultando em diferentes valores para o comprimento de borda $L(r)$ de cada círculo. Assim, o valor DD é encontrado através da Equação 2.19.

$$DD = \lim_{r \rightarrow 0} \frac{\log L(r)}{\log(1/r)} \quad (2.19)$$

Por fim, CD é uma medida de dimensionalidade, calculada através da 2.20:

$$CD = \lim_{r \rightarrow 0} \frac{\log C(r)}{\log(1/r)} \quad (2.20)$$

Em que $C(r)$ é dada por:

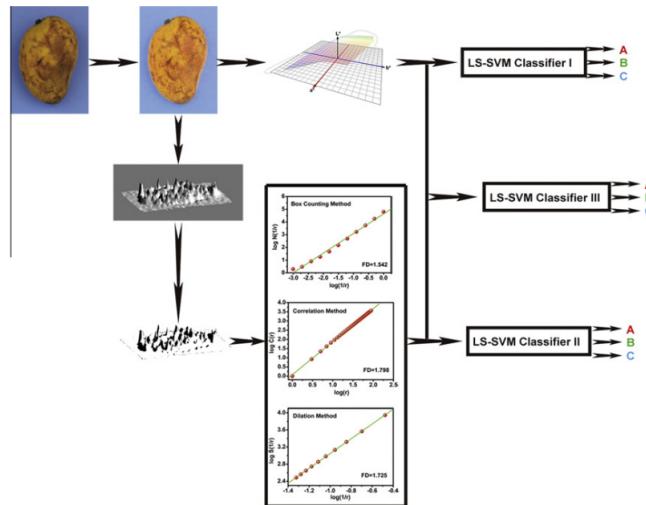
$$C(r) = \lim_{n \rightarrow \infty} \frac{1}{N^2} \sum_{j=1}^N \sum_{i=j+1}^N \theta(r - \|R_i - R_j\|) \quad (2.21)$$

Em que r é uma distância limiar, N é o número de pontos, θ é a função de *Heaviside* e R representa os pontos.

Assim, três diferentes modelos LS-SVM foram computados: um que utiliza apenas as variáveis de cor, outro para as variáveis fractais e o terceiro para todas as variáveis.

A Figura 10 exibe as etapas realizadas pelos autores, desde o pré-processamento até a construção dos modelos.

Figura 10 – Pré-processamento das imagens, extração de seus atributos e posterior construção dos modelos LS-SVM.



Fonte: (ZHENG; LU, 2012).

Os parâmetros ótimos da LS-SVM foram obtidos por uma busca em *grid* aliada à validação cruzada *full*. 70% das amostras foram escolhidas aleatoriamente para o treinamento da LS-SVM e as demais para o teste, resultando em uma acurácia igual a 100% para o modelo com todas as variáveis. Por outro lado, o modelo que emprega apenas as variáveis $L^*a^*b^*$ e o que utiliza as variáveis fractais obtiveram acuráncias iguais a 88,89% e 85,19% respectivamente.

No trabalho de Khairunniza-Bejo e Kamarudin (2011), determinou-se a docura de mangas Chokanan² com o emprego do espaço de cores HSB (ou HSV). O lote colhido pelos autores continha mangas em seis diferentes estádios de maturação. Os valores de SST foram obtidos através de um refratômetro digital em um ambiente a 24,6 °C. As imagens foram tiradas por uma câmera CCD a 40 cm de distância da manga, em uma sala com iluminação apropriada, resultando em 180 imagens tiradas.

O valor médio dos pixels no espaço HSB foi obtido para cada imagem, conforme mostra a Figura 11. Cada variável foi empregada para um modelo de regressão linear separadamente, de forma que fosse determinado o melhor canal para determinação de SST em mangas Chokanan².

A faixa de valores de SST foi dividida em três índices ($4,0^\circ - 8,0^\circ$, $8,0^\circ - 13,0^\circ$ e $13,0^\circ - 17,0^\circ$), de forma que os resultados estivessem em função de cada faixa. Ademais, os três modelos construídos utilizaram 50% das imagens enquanto que as demais foram

Figura 11 – Extração de atributos realizada pelos autores.



Fonte: (KHAIRUNNIZA-BEJO; KAMARUDIN, 2011).

empregadas para o teste.

A melhor variável obtida foi a matiz, que alcançou uma correlação de Pearson igual a -0,92, enquanto que a saturação e brilho alcançaram coeficientes iguais a 0,85 e 0,66 respectivamente. A matiz apresentou também o menor desvio padrão para os três índices (2,73, 6,31 e 2,44), enquanto que o desvio padrão para o brilho indicou que os valores dos pontos eram bastante dispersos (35,15, 18,09 e 22,79 nos índices 1, 2 e 3 respectivamente). O modelo que emprega matiz apresentou os menores valores para erro médio quadrático no índice 2 e 3 (0,22 e 0,03 °Brix respectivamente) e a maior Raiz do erro quadrático médio (*RMSE, Root Mean Square Error*) para o índice 1 (0,06 °Brix). Os modelos com saturação apresentaram os maiores RMSE nos índices 1 e 3, enquanto que o modelo com brilho foi superior no índice 1. Como a diferença entre os erros foi pequena, considerou-se que a matiz provou ser a melhor variável para determinação de SST em mangas, devido ao melhor valor de correlação de Pearson.

Yossy et al. (2017) propôs um sistema de classificação de mangas quanto ao estádio de maturação e tamanho com o emprego de redes neurais. 52 mangas da variedade Gincu³ foram empregadas para o treinamento do modelo. Elas possuíam dois tamanhos diferentes (grande e pequeno) e dois estádios diferentes (verde e madura), assim, as classes definidas pelos autores foram grande-madura, pequena-madura, grande-verde e grande-pequena. As

³A variedade Gedong Gincu é uma das mais populares da Indonésia, lugar de onde se originou. Ela possui um tamanho médio, com seu comprimento entre 10 e 12cm, e peso entre 200 e 250g. Além disso, ela tem um formato arredondado, cor alaranjada e sabor adocicado.

imagens foram tiradas através de uma *webcam* a 30 cm de distância e armazenadas como JPEG.

Duas abordagens de pré-processamento foram empregadas a partir da imagem RGB: na primeira, o espaço de cores RGB foi convertido para HSV e as faixas dos valores H, S e V foram determinadas para a etapa posterior de transformação dos pixels em um *array*. Em seguida, foram aplicadas operações de abertura e fechamento visando a eliminação de objetos e buracos pequenos respectivamente. Por fim, a imagem foi redimensionada para 16x16 pixels visando a redução de tempo computacional. Na segunda abordagem, a partir da imagem RGB obteve-se a imagem em escala de cinza, que foi limiarizada para a obtenção do contorno da manga. Tendo obtido o contorno, um retângulo foi desenhado ao redor dele. A partir deste retângulo foram obtidas sua largura e altura, que representam o tamanho do objeto de forma simbólica. As duas medidas foram convertidas para centímetro. Os pixels da imagem 16x16 foram representados em um *array* de 257 posições, sendo que os 256 primeiros valores correspondiam às cores dos pixels da imagem (1 - verde, 2 - vermelho, 3 - laranja e 0 para outra cor) e a última posição do *array* conteve o tamanho da respectiva manga (6 - grande e 7 - pequena). Este *array* foi então utilizado como entrada da rede neural, que possuía função de ativação sigmoide e treinamento por *back propagation*. O treinamento foi realizado para as 52 amostras com diferentes taxas de aprendizado (0,000001 e 0,0001) e número de camadas escondidas (5, 20, 25, 40, 50, 60, 75, 80, 100).

Os autores obtiveram como melhor resultado uma acurácia igual a 94% ao empregar 40 camadas escondidas e taxa de aprendizado igual a 0,0001, alcançando um tempo de treinamento igual a 4 segundos. Entretanto, a escolha de camadas escondidas é questionável, pois é introduzida no modelo uma quantidade de parâmetros livres maior do que de atributos de entrada. Apesar disto os autores obtiveram bons resultados, o que pode indicar um *overfitting* do modelo, visto que não foi mencionado o emprego de um conjunto de teste.

O resultado obtido pelos autores foi ligeiramente inferior ao obtido por Jatmika e Purnamasari (2014), que alcançaram uma acurácia igual a 100% na classificação de mangas quanto ao estádio de maturação, mas maior que o obtido por Permadi et al. (2015), que obteve uma acurácia igual a 75% na discriminação dos estádios de maturação do pepino.

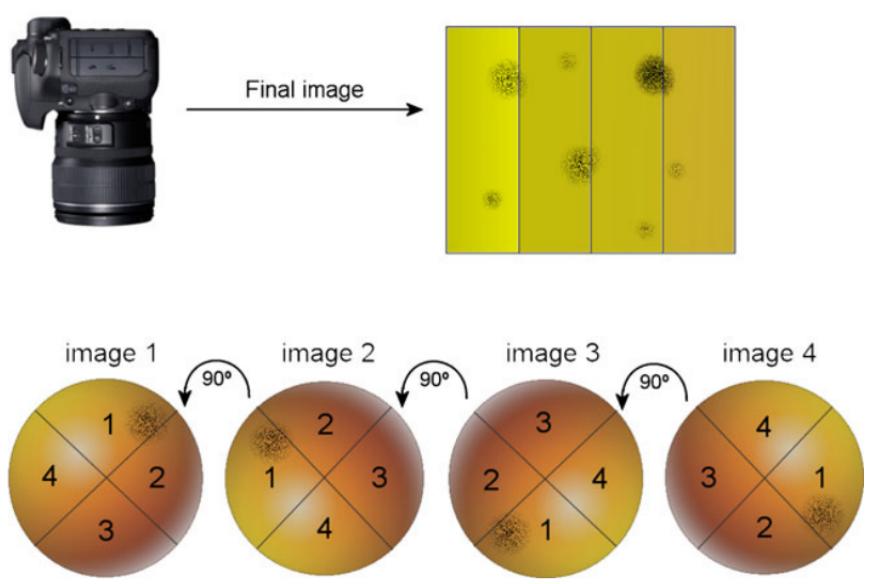
No estudo de Vélez-Rivera et al. (2014), estimou-se o estádio de maturação de mangas da variedade Manila⁴ empregando como atributos sólidos solúveis, acidez, firmeza, índice RPI (*Ripening Index*) e média dos pixels nos espaços de cores L*a*b* e HSB,

⁴Variedade nativa das Filipinas caracterizada por um formato semielíptico, cor levemente verde que amarela conforme a maturação. Sua textura é suave, suculenta e pouco fibrosa e é conhecida por ser muito doce quando está madura.

totalizando dez variáveis de entrada. Foram obtidos dois lotes de um mercado, sendo que o primeiro, contendo 117 amostras, foi utilizado para treinamento do modelo, enquanto que o segundo lote com 39 mangas foi empregado para a checagem da robustez do modelo. As mangas coletadas possuíam diferentes estádios de maturação, formato e tamanho, mas todas possuíam a superfície sem defeito. Elas foram limpas por uma solução com 1% de NaOCl por dez minutos, lavadas com água destilada e secas em temperatura ambiente. As amostras foram armazenadas no escuro a 25 °C e 75% de umidade relativa por 13 dias em uma câmara. Em cada dia 9 mangas eram coletadas para a aquisição de imagens e obtenção de parâmetros físico-químicos.

Foi utilizada uma lâmpada fluorescente circular de 32 W para a iluminação, com a imagem tirada por uma câmera Rebel XS W18-55Is de 24 MP, capturada com 3888x2592 pixels no formato JPEG e armazenadas como TIFF. Foram tiradas quatro fotos das mangas inteiras, sendo que elas foram rotacionadas em 90° a cada foto, conforme mostra a Figura 12. De cada imagem extraiu-se a faixa central ao longo do comprimento da manga, e assim, a imagem final foi composta pelas quatro faixas.

Figura 12 – Processo de obtenção da imagem final a partir de rotações da manga.



Fonte: (VÉLEZ-RIVERA et al., 2014).

De cada imagem foram obtidos os atributos referentes aos espaços de cores L*a*b* e HSV. A respectiva manga teve então sua polpa removida visando a obtenção dos valores de SST através de um refratômetro digital, enquanto que a acidez foi obtida por uma titulação com 0.1 NaOH e a firmeza por um teste de penetração. O índice de maturação RPI foi calculado a partir dos valores obtidos anteriormente de SST, acidez e firmeza.

Após a obtenção dos atributos, empregou-se PCA (Análise de componentes prin-

pais – *Principal Component Analysis*) para a determinação das variáveis mais significativas e MDA com intervalo de confiança a 95% para a classificação. Com as dez variáveis empregadas, obteve-se uma variância explicada igual a 93,71%, com 76,65% para PC1 e 17,06% para PC2. Notou-se também pela PCA que as variáveis menos significativas foram L* e B e, sem elas, obteve-se uma variância explicada igual a 95,18%, com 90,10% para PC1 e 5,08% para PC2. Assim, a MDA foi aplicada para as oito variáveis restantes, resultando em 100% de acurácia na determinação do estádio de maturação das mangas do lote de teste. Ao remover as variáveis físico-químicas, obteve-se uma acurácia média igual a 84,62% e, com apenas a*, b*, H e S, obteve-se 84,62%. Já era esperada uma alta acurácia para o modelo que empregou as variáveis físico-químicas, pois estas consistem em informações a posteriori, ou seja, são determinadas a partir do estádio de maturação das mangas, o que as torna inadequadas para o treinamento do modelo. Além disso, a opção de empregar estas variáveis deturpa o princípio da não destruição das amostras, que consiste na maior vantagem do emprego de processamento digital de imagens para a determinação de atributos de qualidade em frutas.

Yahaya et al. (2015) determinaram os atributos de SST, acidez e firmeza em mangas através de imagens capturadas por um smartphone. Foram coletadas manualmente 57 mangas da variedade Sala⁵ e armazenadas a 16 °C e umidade em 50%. As amostras coletadas estavam em diferentes estádios de maturação, com sua superfície possuindo uma cor uniforme, conforme mostra a Figura 13. As frutas foram iluminadas pela tela de um smartphone *Samsung Galaxy Note 1* e tiveram suas fotos tiradas pela câmera frontal do mesmo, de 8 MP.

Para a determinação dos valores de referência, empregou-se inicialmente um penetrômetro na manga intacta para a obtenção dos valores de firmeza. A manga foi então cortada em cubos e batida num liquidificador para a obtenção do suco. Por fim, usou-se um refratômetro e pHmetro para obtenção do SST e pH a partir do suco. Os valores médios de R, G e B foram obtidos para o treinamento de um modelo de regressão por MLR.

O modelo calibrado para determinação de firmeza possuiu um coeficiente de correlação igual a 0,875 e RMSE igual a 1,392 kgf, enquanto que para o SST e acidez obteve-se 0,814 e 0,913 como coeficiente de correlação respectivamente e 1,218 °Brix e 0,166 pH como RMSE. Ao utilizar o modelo para prever os atributos em amostras não utilizadas no treinamento, foram obtidos coeficientes de correlação iguais a 0,913, 0,814 e 0,875 para a firmeza, SST e acidez respectivamente.

No trabalho de Salunkhe e Patil (2015), determinaram-se os estádios de maturação

⁵As mangas da variedade Sala, originárias da Malásia, são frutas azedas, com comprimento entre 12 a 15 cm e um formato não arredondado. Elas são consumidas preferencialmente quando ainda estão verdes ou quase maduras. Saiba mais em: <http://dahasry.blogspot.com/2011/02/harumanis-vs-sala.html>.

Figura 13 – Mangas da variedade Sala⁵ em diferentes estádios de maturação.



Fonte: (YAHAYA, 2015).

de mangas Alphonso⁶ com base nos espaços de cores RGB e HSV. As frutas foram coletadas frescas e verdes para análise primária, sendo que os testes foram realizados ao longo do ciclo de maturação delas. Após a aquisição das imagens, foi realizada a segmentação da manga através de uma ferramenta pronta, a custo de uma precisão reduzida. Os valores médios das matrizes R, G e B foram obtidos e, a partir destes, as razões R/G e R/B. As imagens foram então convertidas para o espaço de cores HSV, e a razão S/H foi obtida.

Dentre as mangas colhidas, 80 foram classificadas manualmente, com 20 mangas para cada estádio, de forma que foram obtidos limiares (R/G, R/B, S/H) que separassem as classes. A partir das faixas de limiares obtidos, foi desenvolvido um algoritmo para classificação das mangas, através de comandos *if-else*.

Para o teste do algoritmo, foram empregados três conjuntos de 24 mangas em diferentes estádios. Para o modelo com RGB e HSV, respectivamente, obteve-se uma acurácia de 90,4% e 84,2%, taxas de falso positivos iguais a 2,57% e 7,9%, verdadeiros positivos iguais a 89,77% e 86,74%. As razões RGB aumentaram conforme o progresso da maturação, mas com diferentes taxas. A cor azul possuiu o menor peso nas imagens, verde possuiu o maior peso em mangas verdes e o vermelho possuiu o maior peso em mangas completamente maduras.

⁶É uma das variedades mais caras do mundo, majoritariamente cultivada na Índia. Ela é conhecida por sua riqueza de sabor, textura suave e polpa delicada, tornando-a uma das variedades mais procuradas. Sua superfície é amarelada com uma leve coloração vermelha no topo. Saiba mais em: [https://en.wikipedia.org/wiki/Alphonso_\(mango\)](https://en.wikipedia.org/wiki/Alphonso_(mango)).

Pandey, Gamit e Naik (2014) classificaram mangas quanto à sua saúde e tamanho. As mangas coletadas eram das variedades Totapuri⁷, Badami⁸ e Neelam⁹, sendo que elas diferiam quanto ao formato e tamanho. Dentre as 100 colhidas, 60 eram saudáveis e 40 possuíam uma das três seguintes doenças: antracnose, putrefação por bactéria e putrefação na haste. As imagens das mangas foram coletadas por uma câmera digital Nikon DLSR D90, que foi posicionada no topo de uma câmara que também continha uma lâmpada CFL 14 W. A câmera estava conectada a um computador, de forma que as imagens foram transferidas para um cartão de memória. As imagens obtidas possuíam 640x480 pixels.

As imagens obtidas foram convertidas para escala de cinza, tiveram seu tamanho reduzido e foram pré-processados por filtro da mediana visando a redução de ruído. Como o filtro da mediana contribuiu para que as bordas das mangas fossem suavizadas, foi necessário aguçá-las. As imagens então foram segmentadas e passadas para o espaço de cores L*a*b*, em que b* foi utilizado para determinar o limiar entre mangas saudáveis e doentes, sendo que as três doenças analisadas possuíam como sintoma a cor amarronzada/preta das mangas. Para cada fruta, foi estimada a razão de pixels marrons/pretos em relação à área da manga (dada pela soma dos valores da imagem binária resultante da segmentação), e dependendo deste valor, a manga foi classificada como saudável ou doente. Tendo determinado quais mangas eram saudáveis, estas foram classificadas quanto à categoria (medíocre, média e excelente), de acordo com a área e diâmetro, sendo este calculado por meio da área. Um sistema de inferência *fuzzy* foi desenvolvido para determinar a classe da manga a partir de 9 regras *if-then*, utilizando como entradas a área e o diâmetro, conforme a Tabela 1.

Tabela 1 – Regras *fuzzy* adotadas por Pandey, Gamit e Naik (2014) para classificação de mangas quanto a seu tamanho.

Área/Diâmetro	Pequeno	Médio	Grande
Pequena	Qualidade medíocre	Qualidade medíocre	Qualidade medíocre
Média	Qualidade medíocre	Qualidade média	Qualidade média
Grande	Qualidade medíocre	Qualidade média	Qualidade grande

Fonte: (PANDEY; GAMIT; NAIK, 2014).

⁷Variedade cultivada em sua maior parte na Índia e Sri Lanka, possuindo uma cor amarela esverdeada.

⁸As mangas Badami são douradas em sua superfície, possuem uma polpa sem fibras e um aroma floral, com um sabor semelhante às da manga Alphonso⁶.

⁹As mangas desta variedade são originárias da Índia e possuem uma aparência uniforme, cor dourada e um aroma característico. Saiba mais em: <http://www.sunrisenaturals.in/products/13/neelam-mango-pulp.php>.

Com o sistema de inferência *fuzzy*, os autores obtiveram uma acurácia média igual a 93,33% na classificação quanto à saúde da manga e 91,41% na classificação da categoria dela.

Abarra et al. (2018) determinaram atributos físico-químicos de mangas através dos espaços de cores RGB, L^{*}a^{*}b^{*} e HSV, sendo eles acidez titulável, açúcares totais, amido total, firmeza, acidez, SST e total de açúcares reduzido. 18 mangas da variedade Carabao¹⁰ foram coletadas quando estavam totalmente verdes e sem mancha alguma, com seu armazenamento feito em caixas de papelão a 18 °C e 92% de umidade relativa. Um conjunto de três mangas foi separado para que suas imagens fossem tiradas em cada estádio de maturação, que foi determinado de forma visual. Foram definidos seis estádios, que foram representados por um índice de cor (1- completamente verde, 2 - quebra de cor, 3 - mais verde que amarelo, 4 - mais amarelo que verde, 5 - amarelo com resquícios de verde e 6 - completamente amarelo). Um conjunto de três mangas foi separado para cada estádio de maturação para que as análises destrutivas fossem realizadas. Alguns dos atributos físico-químicos desejados, como acidez titulável, açúcares totais e amido total foram obtidos quimicamente, enquanto que a firmeza, acidez, SST e total de açúcares reduzido foram determinados por um penetrômetro, phmetro, refratômetro e espectrofotômetro respectivamente.

As mangas foram colocadas em uma caixa de madeira compensada, cujo interior possuía dois LEDs brancos e um buraco para a inserção da câmera digital de 14,1 MP (GE E1450W). Duas fotos foram tiradas para cada manga, uma para cada lado da mesma, e então os atributos foram extraídos de cada imagem, sendo eles os valores médios de R, G, B, L^{*}, a^{*}, b^{*}, H, S e V. As funções para determinação destes atributos foram formuladas como combinações de um, dois ou três canais de cores. Os valores calculados por essa função foram plotados versus os valores de referência, para avaliação do coeficiente de correlação.

Os autores notaram que os melhores resultados obtidos foram aqueles que empregaram o espaço de cores RGB para determinação da acidez titulável e firmeza, não informando os resultados obtidos para os demais atributos físico-químicos. Assim, para a acidez, obtiveram-se os coeficientes 0,917, 0,948, 0,915 e 0,977 para R, G, B e L^{*} respectivamente e 0,924 e 0,948 para R+G e R+G+B. Para a firmeza, os coeficientes de correlação obtidos foram 0,899, 0,941, 0,933 e 0,968 para R, G, B e L^{*} respectivamente e 0,906 e 0,948 para R+G e R+G+B. Os resultados obtidos para firmeza foram ligeiramente inferiores aos encontrados por Domingo et al. (2013), que determinou a firmeza em mamões, alcançando os coeficientes de correlação 0,9387 e 0,9497 para as funções binária e ternária em RGB, respectivamente.

¹⁰Também conhecida como manga Manila⁴.

2.2.1 Síntese dos trabalhos estudados

A seguir são sumarizadas as variáveis de entrada e saída, técnicas e métricas empregadas pelos autores.

Tabela 2 – Atributos-alvo determinados pelos autores.

Autores/Atributos-alvo	Peso	Maturação	Apodrecimento	Tamanho	SST	Acidez	Firmeza	Doença
Teoh e Syaifudin (2007)	X							
Nandi, Tudu e Koley (2014)			X					
Zheng e Lu (2012)			X					
Khairunniza-Bejo e Kamarudin (2011)					X			
Yossy (2017)		X		X				
Vélez-Rivera (2014)		X						
Yahaya (2015)					X	X	X	
Salunkhe (2015)	X							
Pandey (2014)				X				X
Abarra (2018)					X	X	X	

Fonte: (Autor, 2019).

Nota-se que na maioria dos artigos é feita a classificação ao invés da regressão, devido ao fato de os atributos qualitativos previstos serem facilmente determinados através de uma inspeção visual. Isto é comprovado pelos bons resultados encontrados pelos autores, enquanto que nos artigos em que o atributo alvo é quantitativo, as métricas obtidas foram inferiores.

Tabela 3 – Atributos extraídos pelos autores.

Autores/Atributos	Média RGB	Diferença de médias e gradiente RGB	Taxas R/G, R/B e S/H	Média HSV	Canal dominante	Média L*a*b*	Número de pixels	Variáveis fractais	Diâmetro
Teoh e Syaifudin (2007)							X		
Nandi, Tudu e Koley (2014)			X						
Zheng e Lu (2012)						X		X	
Khairunniza-Bejo e Kamarudin (2011)					X				
Yossy (2017)						X			
Vélez-Rivera (2014)				X		X			
Yahaya (2015)	X								
Salunkhe (2015)	X		X	X					
Pandey (2014)						X	X		X
Abarra (2018)	X			X		X			

Fonte: (Autor, 2019).

O pré-processamento das imagens foi realizado em poucos trabalhos, visto que na maioria deles a aquisição das imagens foi realizada sob boas condições. Neste estudo

investigativo essas quatro técnicas serão testadas, para verificação se há uma melhora na capacidade preditiva do modelo.

Percebe-se uma grande variedade de atributos empregados pelos autores, mas com uma predominância dos valores médios dos pixels nos diferentes espaços de cores. O sistema HSV foi o mais empregado por se aproximar mais da percepção de cores do ser humano.

Tabela 4 – Técnicas de inferência utilizadas nos trabalhos estudados.

Autores/Técnicas	Regressão linear	MLR	SVM	LS-SVM	Rede neural	MDA	Sistema fuzzy	Regras de produção
Teoh e Syaifudin (2007)	X							
Nandi, Tudu e Koley (2014)			X					
Zheng e Lu (2012)				X				
Khairunniza-Bejo e Kamarudin (2011)		X						
Yossy (2017)					X			
Vélez-Rivera (2014)						X		
Yahaya (2015)		X						
Salunkhe (2015)							X	
Pandey (2014)								X
Abarra (2018)	X							

Fonte: (Autor, 2019).

Para os problemas de classificação, é visível o emprego de diferentes técnicas para a predição de atributos. Por outro lado, os autores que realizaram regressão em seus trabalhos optaram por técnicas menos sofisticadas, a Regressão linear e MLR, supondo uma relação linear entre as variáveis de entrada e saída.

As métricas empregadas pelos autores serão também empregadas neste estudo investigativo, para comparação direta com os resultados obtidos por eles.

Tabela 5 – Métricas empregadas pelos autores.

Autores/Atributos-alvo	Coeficiente de correlação	RMSE	Acurácia	Taxa de falsos positivos e verdadeiros positivos
Nandi, Tudu e Koley (2014)		X		
Zheng e Lu (2012)		X		
Khairunniza-Bejo e Kamarudin (2011)				
Yossy (2017)		X		
Vélez-Rivera (2014)		X		
Yahaya (2015)	X	X		
Salunkhe (2015)			X	
Pandey (2014)			X	
Abarra (2018)	X			

Fonte: (Autor, 2019).

3 MATERIAL E MÉTODOS

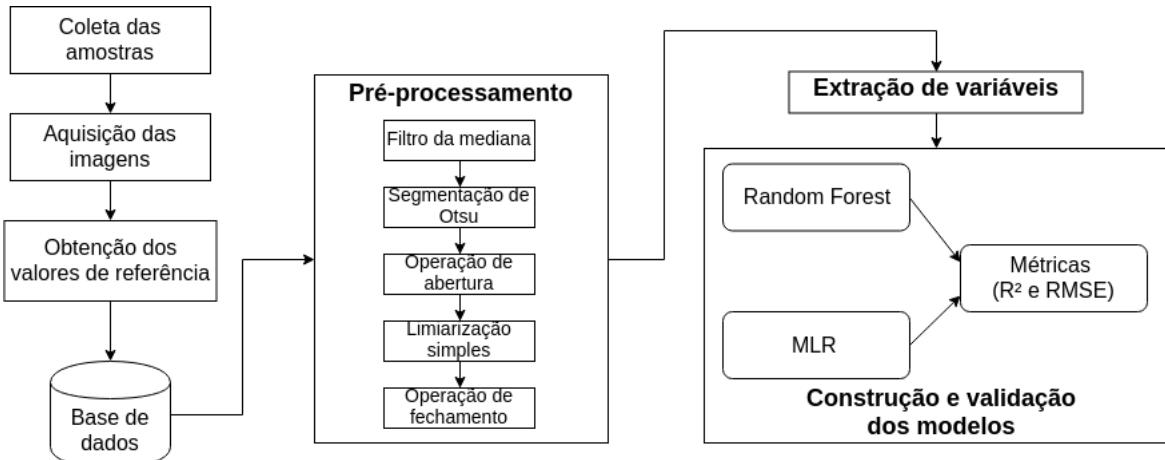
O presente trabalho consiste em uma pesquisa do tipo quantitativa, por empregar procedimentos estruturados de coleta e análise de dados para descrição de um fenômeno e quantificação de resultados (FONSECA, 2002); quanto à sua natureza, ela é do tipo aplicada, devido aos resultados obtidos poderem ser utilizados para uma aplicação prática; quanto aos objetivos, é uma pesquisa explicativa, devido à busca pelos fatores determinantes para a ocorrência de um fenômeno (GIL, 2007) e, por fim, experimental quanto aos procedimentos adotados.

Dentre os dez artigos estudados, o atributo sólidos solúveis totais foi determinado em apenas três deles. O melhor resultado foi obtido para um modelo simplificado de regressão linear, em que apenas uma variável foi utilizada, enquanto que para os demais modelos os resultados foram medianos ou ruins ao empregar no máximo três variáveis de entrada. Abarra et al. (2018) utilizaram os espaços de cores RGB, HSV e L*a*b*, mas não forneceram os resultados obtidos. Assim, nota-se uma carência de um modelo robusto e generalista para predição de SST. Desta forma, o estudo foi conduzido de forma a investigar quais atributos visuais da manga mais se relacionam a esse atributo de qualidade, para que um bom modelo preditivo seja obtido.

Os atributos a serem extraídos das imagens das mangas foram todos aqueles empregados nos dez artigos, listados na Tabela 3. Estes atributos, juntamente dos valores reais de SST para cada manga, foram utilizados para a construção de modelos preditivos. As técnicas de inferência empregadas foram a Regressão linear e *Random Forest*. Através da Regressão linear foi verificada se há uma relação linear entre as variáveis de entrada e a de saída, assim como foi realizado pelos autores que determinaram SST em seus trabalhos. Ademais, na técnica *Random Forest* todas as variáveis de entrada foram utilizadas em um mesmo modelo, e por meio deste serão determinadas as variáveis mais significativas para a predição de SST em mangas.

O estudo foi conduzido em etapas bem definidas, iniciando-se na coleta das amostras e finalizando na construção e validação dos modelos, conforme mostra a Figura 14. Cada etapa será descrita nas subseções posteriores.

Figura 14 – Etapas do estudo, desde a coleta das frutas até a validação dos modelos.



Fonte: (Autor, 2019).

3.1 COLETA DAS AMOSTRAS

As mangas utilizadas no estudo eram da variedade ‘Palmer’, sendo uma das variedades mais produzidas no Vale do São Francisco (EMBRAPA SEMIÁRIDO, 2010), sendo caracterizada por frutos aromáticos e grandes, com peso de até 900 g, tom esverdeado ou arroxeados quando estão imaturos e cor vermelha quando maduros.

As amostras foram coletadas de pomares comerciais da Fazenda SpecialFruit Importação e Exportação Ltda. em Petrolina e Juazeiro. Foram marcadas trinta plantas distribuídas em cinco fileiras de plantio de um lote do pomar. A cada quinze dias foram colhidos manualmente 60 frutos (dois de cada planta), para cada variedade, iniciando-se dos 35 dias após a floração¹¹ até o ponto de colheita comercial adotado pela Fazenda, visando a construção de um modelo robusto de predição, onde mangas de diferentes estádios de maturação fossem utilizadas. As mangas foram analisadas num intervalo de 15 em 15 dias e, após a colheita, de 10 em 10 dias.

3.2 AQUISIÇÃO DAS IMAGENS

As imagens das mangas foram obtidas para cada lado da fruta no mesmo dia em que elas foram coletadas. Elas foram posicionadas em uma caixa de madeira compensada com um orifício no topo (Figura 15), onde foi posicionada uma câmera de 18 MP. O interior da caixa é preto fosco e contém uma superfície não reflexiva para o apoio das mangas. O sistema de iluminação da câmara era constituído por 3 LEDs Solderless XPE2 de 3W

¹¹ Etapa reprodutiva em que ocorre a diferenciação do meristema vegetativo para o floral, originando os componentes da flor (pépalas, estames e pistilo) (DUARTE FILHO et al., 1999).

da CREE, branco frio 5000K a 8300K, dispostos a uma distância angular de 120º entre eles. O equipamento foi obtido a partir de uma parceria com o Laboratório de Energia na Agricultura (LENA) da UNIVASF.

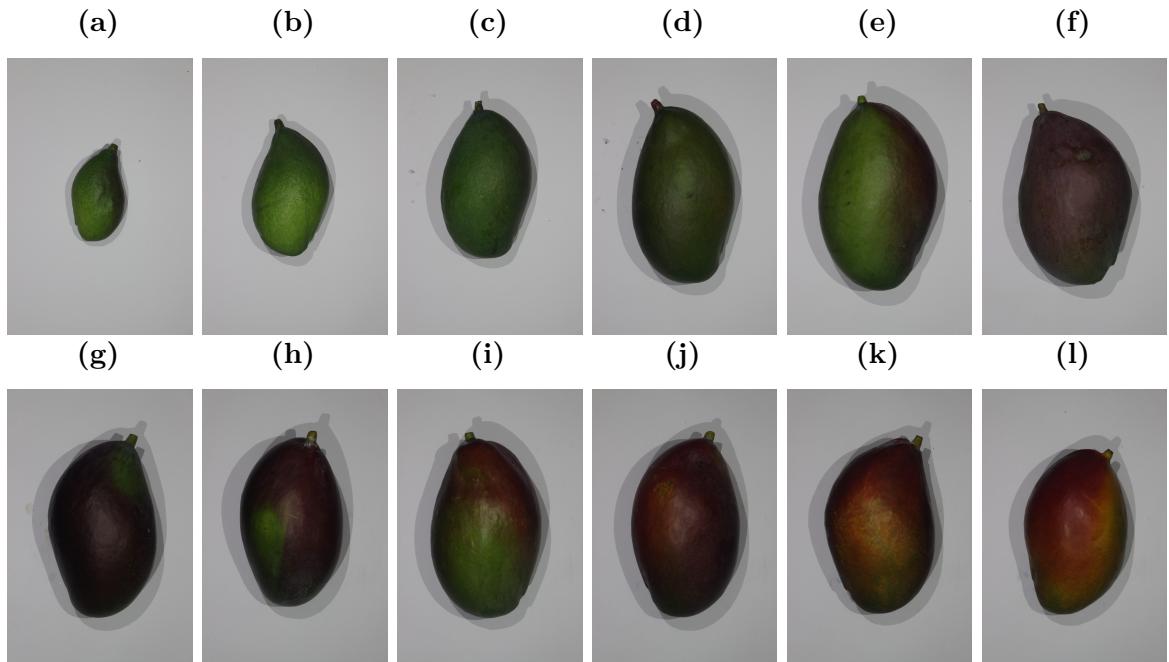
Figura 15 – Câmara para aquisição das imagens.



Fonte: (Autor, 2019).

Foram tiradas fotos de 750 mangas, e, como os dois lados de cada amostra foram fotografados, no total obtiveram-se 1500 imagens. Para a Palmer, foram fotografadas 600 mangas até o dia da colheita e 150 após ela. A Figura 16 exibe fotos da manga Palmer em diferentes estádios.

Figura 16 – Fotos tiradas da manga Palmer (a) 35 dias após a floração (b) 50 dias após a floração (c) 65 dias após a floração (d) 80 dias após a floração (e) 95 dias após a floração (f) 110 dias após a floração (g) 125 dias após a floração (h) 140 dias após a floração (i) 155 dias após a floração (j) 170 dias após a floração (k) 10 dias após a colheita (l) 20 dias após a colheita.



Fonte: (Autor, 2019).

3.3 OBTENÇÃO DOS VALORES DE REFERÊNCIA

Os valores reais de SST foram obtidos segundo o procedimento do Instituto Adolfo Lutz (2008), sendo também adotado por Yahaya et al. (2015). Nele, as mangas têm inicialmente sua polpa homogeneizada e filtrada por uma centrífuga. O suco extraído é colocado em um refratômetro digital (HI 96804, Hanna Instruments, USA) para a quantificação de SST em °Brix.

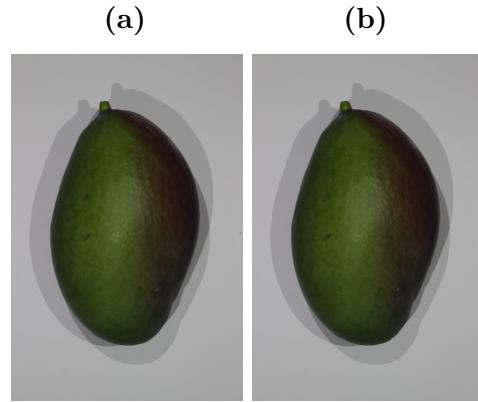
3.4 PRÉ-PROCESSAMENTO

Como as imagens obtidas possuíam ruído e informações irrelevantes, foi necessário realizar o pré-processamento das mesmas. Foram testadas diferentes configurações de algoritmos, de forma a remover a maior quantidade possível de ruído sem perda de informações importantes da imagem. Apesar de as fotos terem sido tiradas em um ambiente controlado, as imagens resultantes variaram quanto ao ruído nelas contido, devido ao acúmulo de sujeira na câmara com o passar das semanas do experimento. Sendo assim, as configurações das técnicas variaram para cada imagem.

A primeira técnica aplicada foi o filtro da mediana, visando a remoção de manchas contidas nas imagens. O tamanho de janela que garantiu uma melhor remoção de ruído na

maioria das imagens foi de 11x11 pixels. Na Figura 17, são mostradas a imagem original de uma manga e sua versão pré-processada com filtro da mediana.

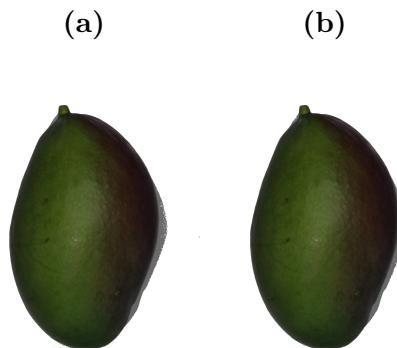
Figura 17 – Antes e depois da filtragem por filtro da mediana (a) Imagem original (b) Imagem tratada pelo filtro da mediana.



Fonte: (Autor, 2019).

Após isso, as imagens foram segmentadas através do algoritmo de Otsu, de forma que as mangas fossem isoladas do fundo. Com isso, notou-se nas imagens a presença de pequenos pontos que não foram removidos pelo filtro da mediana. Apesar de a remoção dos mesmos ser possível com uma segunda filtragem pela mediana, notou-se uma perda de detalhes na manga. Sendo assim, optou-se por empregar a operação de abertura, através da qual pequenos pontos da imagem foram removidos, ao empregar um *kernel* variando entre 15x15 e 105x105 pixels. A Figura 18 mostra a imagem segmentada e tratada pela operação de abertura.

Figura 18 – Segmentação e operação de abertura na imagem (a) Imagem segmentada (b) Imagem tratada pela operação de abertura.

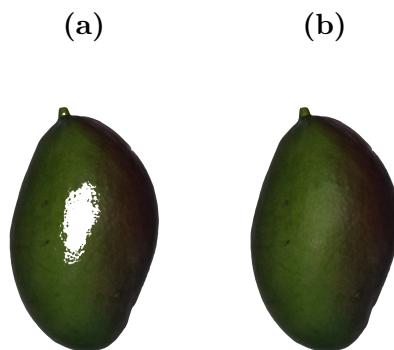


Fonte: (Autor, 2019).

A utilização destas técnicas não garantiu uma remoção completa das sombras contidas na imagem. Assim, utilizou-se a limiarização simples para este fim, visto que

a intensidade dos pixels correspondentes às sombras era, em geral, visivelmente menor que a intensidade dos pixels das mangas. A configuração desta técnica que conferiu os melhores resultados possuiu um *threshold* igual a 100, aplicado na imagem em escala de cinza. Como a limiarização simples resultou na remoção de partes da manga, além das sombras delas, empregou-se a operação morfológica de fechamento para o preenchimento das mangas. O melhor tamanho do *kernel* obtido foi de 13x13 pixels. Na Figura 19, são mostradas a figura limiarizada e tratada pela operação de fechamento.

Figura 19 – Limiarização simples e operação de fechamento na imagem (a) Imagem limiarizada (b) Imagem tratada pela operação de fechamento.



Fonte: (Autor, 2019).

Por fim, foram traçados os contornos das mangas, visando a remoção de partes da imagem que não continham a fruta, através da função *findContours* do OpenCV. A Figura 20 mostra a imagem final após todas etapas de pré-processamento.

Figura 20 – Imagem pré-processada resultante.



Fonte: (Autor, 2019).

Posteriormente, as variáveis mencionadas na Tabela 3 foram extraídas para cada imagem. Todos os algoritmos de pré-processamento de imagens foram realizados através da linguagem de programação Python, com o auxílio da biblioteca OpenCV.

3.5 EXTRAÇÃO DE VARIÁVEIS

Com o pré-processamento, foi possível realizar a extração de variáveis sem a interferência de informações irrelevantes. Para a maioria dos atributos não foi necessário realizar nenhuma manipulação adicional nas imagens. Para o atributo número de pixels, entretanto, a versão binária da imagem foi utilizada, de forma que os pixels correspondentes à manga possuíssem o valor 1 e os pixels correspondentes ao plano de fundo possuíssem o valor 0. Assim, através da soma desses valores foi obtida uma estimativa da área da manga, a partir da qual foi calculado o seu diâmetro. As variáveis fractais, por outro lado, exigem um custo computacional maior para sua determinação. Assim, antes da extração destes atributos, as imagens foram reduzidas para um terço do seu tamanho original.

O atributo cor dominante HSV foi obtido a partir de um mapeamento do valor da matiz para uma das cores presentes no cone HSV, mostrado previamente na Figura 2. O gradiente RGB foi obtido após o ajuste de uma reta para os valores RGB da manga ao longo de seu eixo longitudinal. Para o canal que resultasse num melhor ajuste da reta, foi obtido o intercepto da respectiva reta.

Por fim, os demais atributos, associados à média das intensidades dos pixels, foram obtidos com o auxílio da biblioteca *Numpy* e sua função *mean*, que retorna a média dos valores de uma matriz ou *array*. Como as imagens estavam originalmente representadas no espaço RGB, foi necessário realizar a conversão para os espaços HSV e L*a*b* antes da obtenção da média dos pixels nestes espaços.

3.6 CONSTRUÇÃO E VALIDAÇÃO DOS MODELOS

Antes da construção dos modelos foi realizada uma reamostragem das imagens, devido ao desbalanceamento presente na base de dados. Como havia 600 imagens de mangas tiradas antes da colheita e apenas 240 imagens tiradas após ela, foi feita uma repetição das imagens deste período até que fosse obtida uma quantidade igual de imagens nos dois períodos.

A construção dos modelos foi feita através da biblioteca *Scikit-Learn*, assim como a validação e obtenção das métricas. Como foi utilizada a estratégia *5-fold cross-validation*, em cada uma das 5 iterações 240 amostras eram utilizadas para teste e as demais para treinamento do modelo. A partir dos valores reais e previstos, os valores de *R* e *RMSE* foram calculados.

Assim, foram construídos modelos de *Random Forest* e Regressão linear em que as variáveis de entrada foram utilizadas em artigos que determinavam SST. Os autores Khairunniza-Bejo e Kamarudin (2011) utilizaram a matiz, do espaço HSV, enquanto Yahaya et al. utilizaram os três canais do espaço RGB. Abarra et al. (2018) utilizaram os espaços RGB, HSV e L*a*b*, mas como não forneceram resultados, o experimento deles

não foi replicado.

Por fim, foi construído um modelo que reúne todas as variáveis encontradas na literatura, já listadas na Tabela 3, de forma a encontrar as variáveis mais significantes para predição de SST em mangas da variedade Palmer.

4 RESULTADOS E DISCUSSÃO

A estatística descritiva do atributo sólidos solúveis totais é mostrada na Tabela 6, onde nota-se uma grande variabilidade nos dados. Dessa forma, é possível construir um modelo robusto capaz de realizar a predição deste atributo para diferentes estádios de maturação da manga.

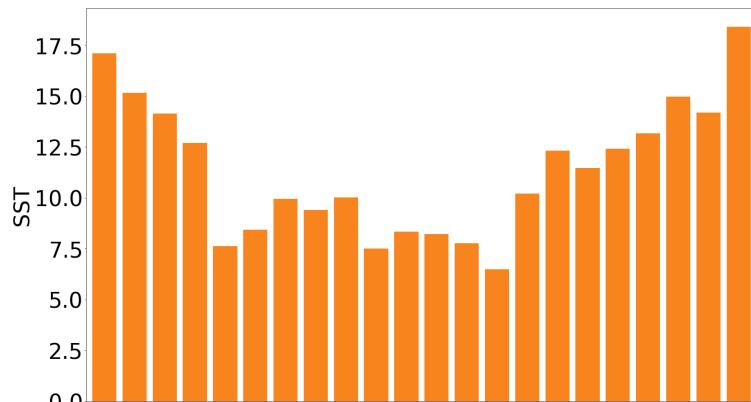
Tabela 6 – Estatística descritivas dos valores de referência dos sólidos solúveis totais.

Dados	Amostras	Média	Mín	Máx	Amplitude	SD	Variância
SST	1200	9,83	3,8	19,7	15,9	4,5	20,24

Fonte: (Autor, 2019).

Inicialmente os modelos construídos na literatura foram replicados para as mangas Palmer, para a comparação dos resultados. No trabalho de Khairunniza-Bejo e Kamarudin (2011), o atributo SST foi previsto em mangas Chokanan a partir do espaço de cores HSV. Os autores construíram modelos de Regressão Linear Simples para cada canal deste espaço de cor, e obtiveram como melhor resultado um coeficiente de correlação igual a -0,92 para o canal matiz. Assim, para as mangas da variedade Palmer, também foi construída uma Regressão linear com o atributo matiz como entrada. Entretanto, os resultados foram inferiores aos obtidos pelos autores, visto que, para as mangas Palmer, o atributo matiz não variou linearmente. A Figura 21 mostra a variação do SST de acordo com a matiz.

Figura 21 – Variação do SST conforme a matiz.

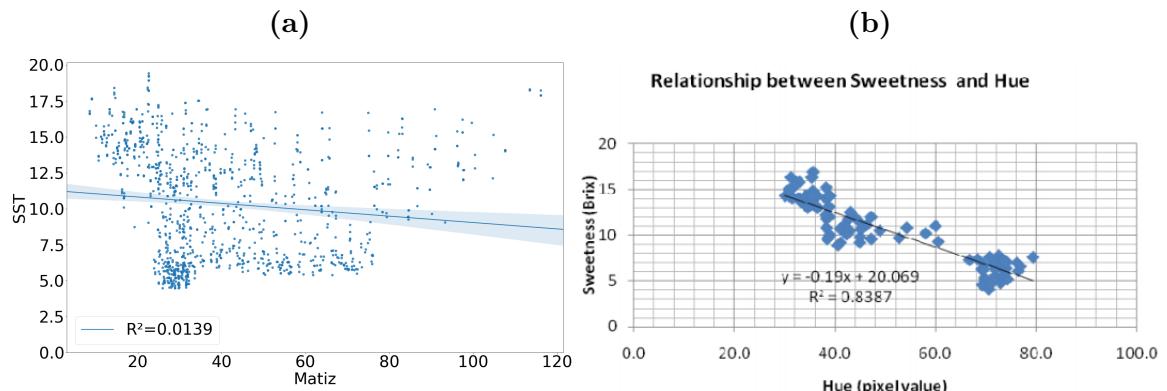


Fonte: (Autor, 2019).

Conforme esperado, o coeficiente de correlação obtido para a Regressão linear foi muito inferior, com um valor igual a -0,1179. Na Figura 22, são mostradas a reta ajustada

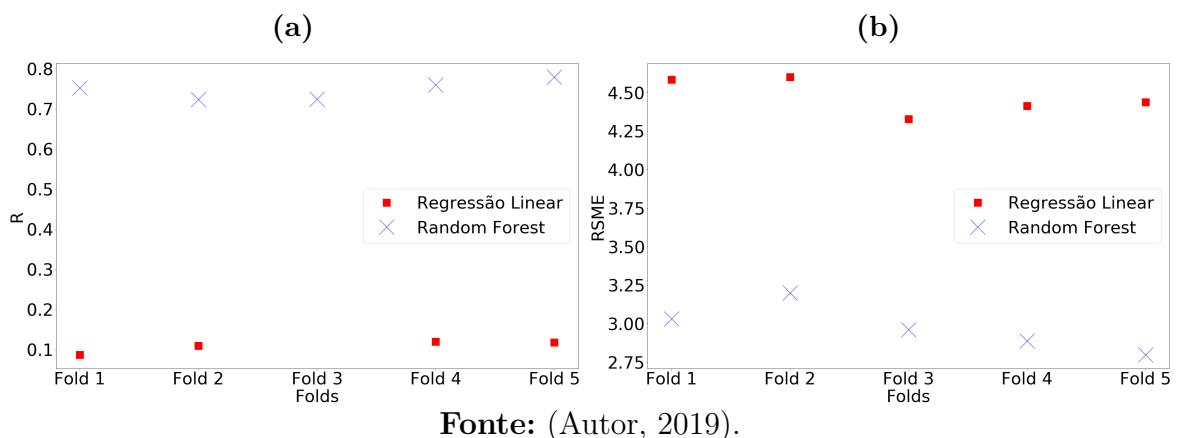
para as amostras do presente estudo e a reta ajustada pelos autores Khairunniza-Bejo e Kamarudin (2011).

Figura 22 – Modelos de Regressão linear construídos para o atributo matiz (a) Presente estudo (b) Trabalho de Khairunniza-Bejo e Kamarudin (2011).



Devido à relação não linear entre a matriz e SST, esperava-se que com a *Random Forest* fosse obtido um resultado superior. Os valores de R e $RMSE$ obtidos por ela e pela Regressão linear, para cada *fold*, são mostrados na Figura 23.

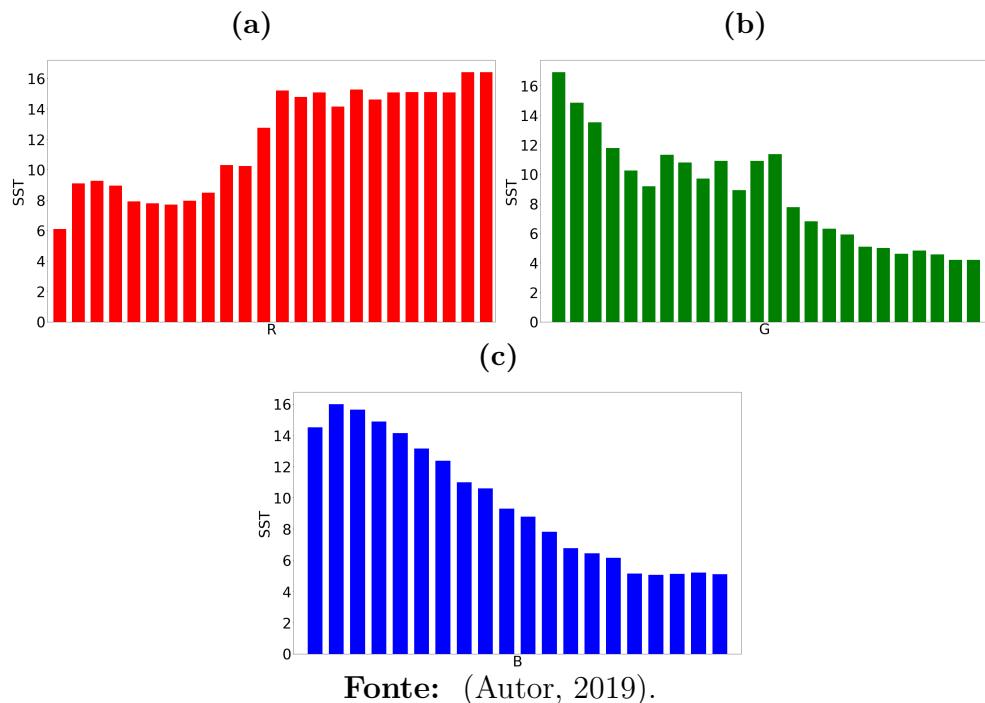
Figura 23 – Resultados obtidos para a matriz (a) Coeficiente de correlação (R) (b) RMSE.



Apesar de a *Random Forest* ser claramente superior à Regressão linear múltipla, como esperado, o resultado ainda é inferior ao obtido pelos autores. Enquanto eles alcançaram um coeficiente de correlação igual a -0,92, o coeficiente médio obtido pela técnica *ensemble* não alcançou o valor de 0,8. Ademais, o RMSE obtido no estudo é muito maior que o obtido por eles ($0,033^{\circ}\text{Brix}$). Para as mangas da variedade Palmer, vê-se que este atributo não é suficiente para a determinação de SST como foi para as mangas da variedade Chokanan.

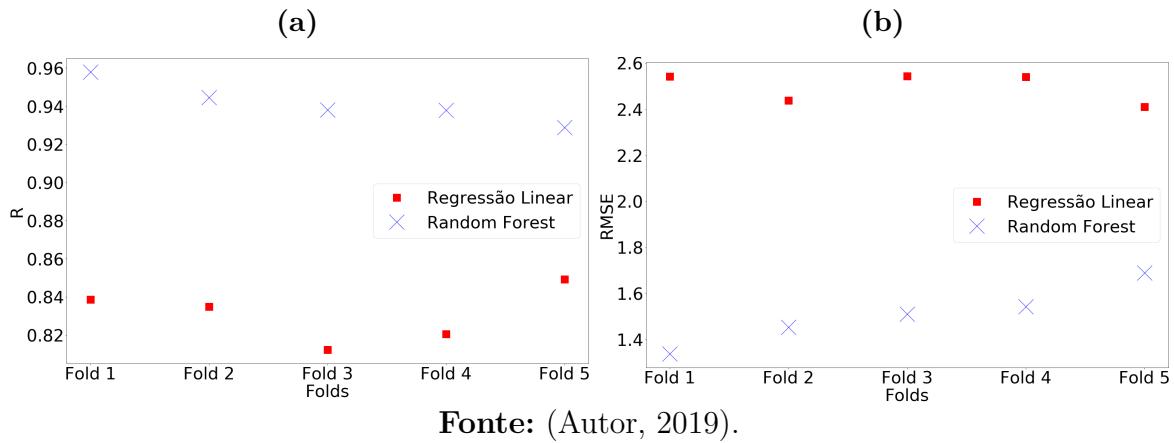
Por outro lado, os autores Yahaya et al. (2015) testaram o espaço de cores RGB e obtiveram um coeficiente de correlação igual a 0,814 e RMSE igual a 1,218 ^aBrix em mangas da variedade Sala. Para verificar se existe uma relação linear entre as variáveis RGB extraídas das mangas Palmer e o SST, foram plotadas as variações das mesmas, mostradas na Figura 24.

Figura 24 – Variação do SST conforme as variáveis RGB (a) Canal R (b) Canal G (c) Canal B.



Nota-se um comportamento aproximadamente linear para as três variáveis. Assim, esperava-se que, através da Regressão Linear Múltipla, fosse obtido um coeficiente de correlação maior que o obtido para a matriz. Na Figura 25, são mostrados os valores de R e RMSE para a Regressão Linear e também a *Random Forest* em todos os *folds*.

Figura 25 – Resultados obtidos para as variáveis RGB (a) Coeficiente de correlação (R) (b) RMSE.



Fonte: (Autor, 2019).

Os valores médios dos coeficientes de correlação para a MLR e RF foram, respectivamente, iguais a 0,8312 e 0,9415. Ambas métricas mostraram-se superiores à obtida por Yahaya et al. (2015). Entretanto, o valor de RMSE obtido pelos referidos autores foram menores que os alcançados para as mangas da variedade Palmer.

4.1 MODELO COM TODAS AS VARIÁVEIS

Assim, para a obtenção de um modelo que melhor explique a variação de SST, foi construída uma *Random Forest* com todas as variáveis listadas na Tabela 3. Com um maior número de variáveis de entrada, há uma maior quantidade de informações associada à cada manga, aumentando-se assim a probabilidade de alcançar melhores resultados. Da mesma forma, foi construída uma Regressão Linear Múltipla com as mesmas variáveis, de forma a verificar se a relação existente entre as variáveis de entrada e o SST é linear. Os valores de R e RMSE para cada *fold* dos modelos RF e MLR são mostrados na Tabela 7.

Tabela 7 – Valores de R e RMSE obtidos pela *Random Forest* e MLR com todas as variáveis.

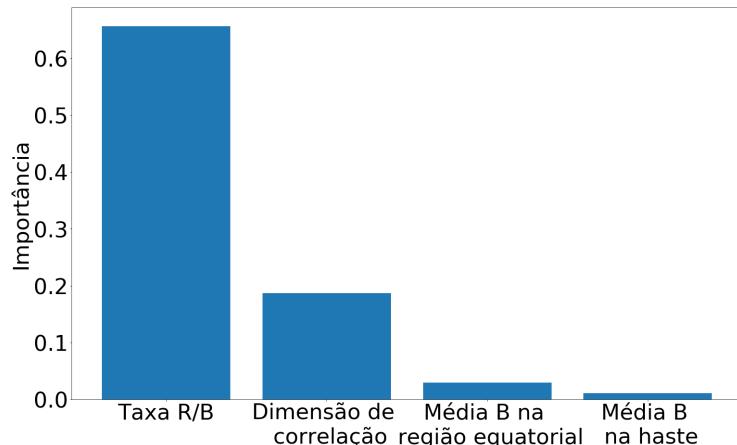
Fold	R		RMSE	
	RF	MLR	RF	MLR
1	0,9723	0,9263	1,0018	1.61544
2	0,9405	0,9227	1,0987	1.73668
3	0,9755	0,9219	0,7075	1.75353
4	0,9634	0,9219	0,9029	1.82808
5	0,9660	0,9064	0,8104	1.85705
Média	0,9789	0,9199	0,9042	1.75816

Fonte: (Autor, 2019).

Nota-se mais uma vez que o modelo *Random Forest* foi superior à Regressão Linear. O coeficiente de correlação obtido por ele foi maior que o encontrado pelos autores Khairunniza-Bejo e Kamarudin (2011) e Yahaya et al. (2015). Por outro lado, enquanto que o RMSE foi menor que o obtido por Yahaya et al. (2015), ainda foi maior que o RMSE encontrado por Khairunniza-Bejo e Kamarudin (2011) em seu trabalho.

Os atributos mais importantes para a determinação de SST em mangas Palmer podem ser obtidos a partir da propriedade *feature_importances_* do *Scikit-Learn*, que retorna um valor de 0 a 1 para cada variável de entrada no modelo RF. Quanto mais próximo de 1 for o valor, mais importante a respectiva variável foi para a construção das regras de decisão da *Random Forest*. Na Figura 26, são mostradas as variáveis mais importantes do modelo.

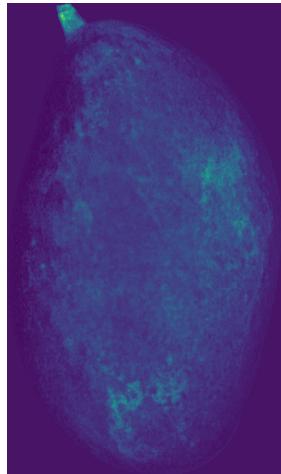
Figura 26 – Atributos mais importantes para a determinação de SST.



Fonte: (Autor, 2019).

Nota-se que o espaço de cores RGB, especialmente o canal B, foi o que mais possuiu relação com o SST. O atributo taxa R/B, que indica a razão entre o valor médio das intensidades no canal R e canal B, foi o mais significativo. Pode-se verificar, através da Figura 27, as intensidades originais dos pixels convertidas para R/B, onde a manga apresenta tons arroxeados.

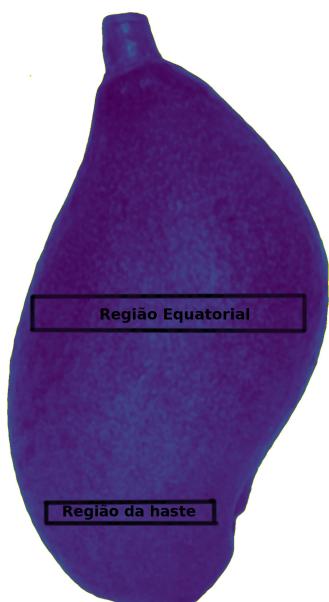
Figura 27 – Representação de uma foto no canal R/B.



Fonte: (Autor, 2019).

O segundo atributo mais importante, a dimensão de correlação, estima o grau de complexidade de um sistema através da inspeção de pontos distribuídos em um espaço (SRIRAAM, 2012), que neste caso consistem nas intensidades dos pixels. Assim, o quanto menos uniforme é a superfície da manga, maior a complexidade. Ademais, os dois outros atributos são associados ao canal azul, em duas regiões específicas a manga. Na Figura 28, são especificadas as regiões equatorial e da haste.

Figura 28 – Regiões equatorial e haste em uma manga representada no canal B.

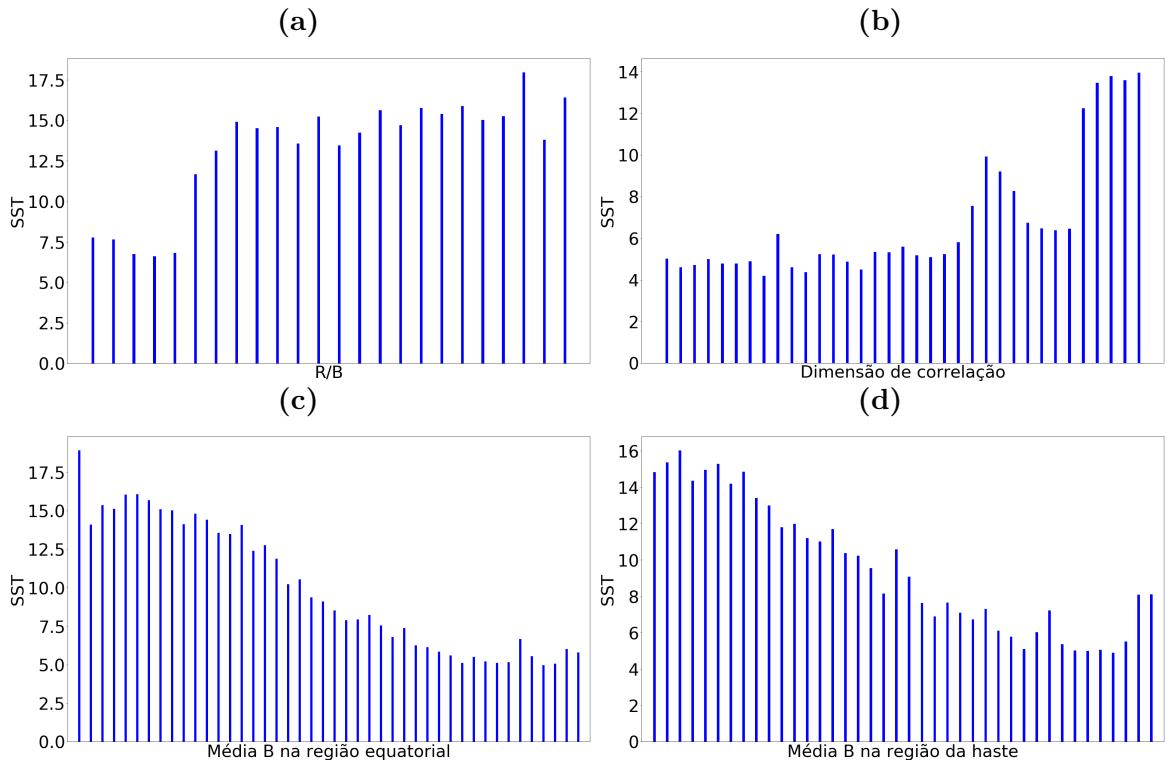


Fonte: (Autor, 2019).

Para entender a relação destas variáveis com os sólidos solúveis totais, foram plotadas as variações delas de acordo com o atributo de qualidade estudado, conforme

mostra a Figura 29.

Figura 29 – Variação dos atributos mais importantes para o modelo conforme o SST (a) Taxa R/B (b) Dimensão de correlação (c) Média B na região equatorial (d) Média B na região da haste.



Fonte: (Autor, 2019).

Para a primeira variável, percebe-se que seus valores mais baixos estão associados à mangas verdes, com baixo teor de SST. Com o aumento desse valor, aumenta-se gradativamente o SST, o que corresponde, na imagem, à uma diminuição dos tons amarelados e intensificação dos tons mais roxos. Para a dimensão de correlação, nota-se um comportamento pouco intuitivo e sem padrão, em que os valores de SST permanecem praticamente constantes para vários valores possíveis da variável. Nas outras duas variáveis, há uma diminuição perceptível do nível de SST enquanto a cor azul torna-se menos intensa nas respectivas regiões da manga.

Os demais atributos extraídos apresentaram importâncias menores que 0,01 e foram desconsiderados na construção de um novo modelo de *Random Forest*. O novo modelo apresentou um coeficiente de correlação igual a 0,9752, bastante próximo ao obtido para todas as variáveis.

5 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS

Com o teste de diferentes técnicas de pré-processamento, visando a maior redução possível de ruído, foi encontrado que as técnicas que proporcionaram um melhor resultado foram o filtro da mediana, as operações de abertura e fechamento, a limiarização simples e a segmentação de Otsu.

Com a extração de atributos e posterior construção dos modelos, concluiu-se que é possível determinar sólidos solúveis totais em mangas Palmer com um coeficiente de correlação igual a 0,9789, o maior encontrado na literatura. Enquanto que para os artigos pesquisados foi assumido um relacionamento linear entre as variáveis de entrada e a de saída, no presente estudo foi investigado se um modelo não linear comportaria-se melhor. Através dos resultados obtidos, concluiu-se que, de fato, um modelo não linear apresenta um desempenho melhor. Este resultado pode ser explicado através da inspeção dos atributos mais importantes, que não variam linearmente.

Verificou-se ainda que o espaço de cor mais significante para a determinação de SST é o RGB, em que o canal B se sobressai. A taxa R/B da imagem mostrou-se o mais importante, seguido do coeficiente de correlação e média do canal B nas regiões equatorial e da haste. A partir dessas quatro variáveis, construiu-se um novo modelo RF, em que o coeficiente de correlação foi igual a 0,9752.

5.1 TRABALHOS FUTUROS

Através deste trabalho, determinou-se as técnicas de pré-processamento, atributos extraídos e algoritmo de predição que conferem o melhor resultado na determinação de sólidos solúveis totais em mangas da variedade Palmer. A partir disso, torna-se possível construir uma aplicação em que, a partir de uma foto tirada da manga, é determinado de forma não destrutiva o nível de SST na fruta. O ideal é que as fotos sejam tiradas em um ambiente controlado, da mesma forma em que foi realizado neste trabalho. Com o uso de um *smartphone*, as fotos poderiam ser tiradas e enviadas a um servidor, que seria responsável por fazer o tratamento das imagens, extrair os quatro atributos mais significantes, obter o nível de SST através da *Random Forest* e retornar este valor ao usuário.

6 REFERÊNCIAS

- ALVES, E. D. L.; VECCHIA, F. A. S. Análise de diferentes métodos de interpolação para a precipitação pluvial no Estado de Goiás. *Acta Scientiarum. Human and Social Sciences*, v. 33, n. 2, 2011. Disponível em: <<http://www.redalyc.org>>. Acesso em: 01 ago. 2018.
- ABARRA, M. S. J. et al. Determination of Fruit Ripeness Degree of ‘Carabao’ Mango (*Mangifera indica L.*) using Digital Photometry. *Philippine Journal of Science*, v. 147, n. 2, p. 249-253, 2018. Disponível em: <<http://philjournalsci.dost.gov.ph/>>. Acesso em: 27 jun. 2018.
- ANUÁRIO BRASILEIRO DE FRUTICULTURA. Santa Cruz do Sul: Editora Gazeta, 2017. Disponível em: <<http://www.editoragazeta.com.br>>. Acesso em: 18 ago. 2018.
- ARCO, J. E. et al. Digital image analysis for automatic enumeration of malaria parasites using morphological operations. *Expert Systems with Applications*, v. 42, n. 6, p. 3041-3047, 2015. Disponível em: <www.sciencedirect.com>. Acesso em: 29 jul. 2018.
- BEDI, S. S.; KHANDELWAL, R. Various image enhancement techniques-a critical review. *International Journal of Advanced Research in Computer and Communication Engineering*, v. 2, n. 3, 2013. Disponível em: <<https://pdfs.semanticscholar.org>>. Acesso em: 29 jul. 2018.
- BRANCO, Danyelle Karine Santos et al. Comportamento das exportações de manga do Vale Submédio São Francisco: uma abordagem a partir de vetores autorregressivos. *Revista Econômica do Nordeste*, v. 47, n. 4, p. 29-37, 2016. Disponível em: <<https://www.bnb.gov.br>>. Acesso em: 04 set. 2018.
- BREIMAN, L. Random forests. *Machine learning*, v. 45, n. 1, p. 5-32, 2001.
- CAMASTRA, F. et al. A fuzzy decision system for genetically modified plant environmental risk assessment using Mamdani inference. *Expert Systems with Applications*, v. 42, n. 3, p. 1710-1716, 2015.
- DA SILVA, L. A.; PERES, S. M.; BOSCAROLI, C. *Introdução à mineração de dados: com aplicações em R*. Elsevier Brasil, 2017.

DE ABREU, A. L. E. *Bootstrap e modelos de Support Vector Machine-SVM*. 2016. 117f. Dissertação (Doutorado em Métodos Numéricos) – Universidade Federal do Paraná, Curitiba, 2016. Disponível em: <www.acervodigital.ufpr.br>. Acesso em: 16 jul. 2018.

DONIS-GONZÁLEZ, I. R. et al. Assessment of chestnut (*Castanea* spp.) slice quality using color images. *Journal of Food Engineering*, v. 115, n. 3, p. 407-414, 2013. Disponível em: <www.sciencedirect.com>. Acesso em: 17 jun. 2018.

DOMINGO, D. L. et al. Digital photometric method for determining degree of harvest maturity and ripeness of ‘Sinta’ papaya (*Carica papaya* L.) fruits. *The Philippine Agricultural Scientist*, v. 95, n. 3, 2013. Disponível em: <<https://journals.uplb.edu.ph>>. Acesso em: 18 jul. 2018.

DORJ, U.; LEE, M.; YUN, S.. An yield estimation in citrus orchards via fruit detection and counting using image processing. *Computers and Electronics in Agriculture*, v. 140, p. 103-112, 2017. Disponível em: <www.sciencedirect.com>. Acesso em: 27 jul. 2018.

DOS SANTOS NETO, J. P. et al. Determination of ‘Palmer’ mango maturity indices using portable near infrared (VIS-NIR) spectrometer. *Postharvest Biology and Technology*, v. 130, p. 75-80, 2017. Disponível em: <www.sciencedirect.com>. Acesso em: 02 jul. 2018.

DUARTE FILHO, J. et al. Aspectos do florescimento e técnicas empregadas objetivando a produção precoce em morangueiros. *Informe Agropecuário*, v. 20, n. 198, p. 30-35, 1999.

EMBRAPA SEMIÁRIDO. *Cultivo da mangueira*. Petrolina, 2002. Disponível em: <<https://ainfo.cnptia.embrapa.br>>. Acesso em: 08 ago. 2018.

ENVI - Guia do ENVI em Português. Sulsoft, 2000. Disponível em: <www.sulsoft.com.br>. Acesso em: 17 jul. 2018.

ESQUEF, A. *Técnicas de entropia em processamento de imagens*. RIO DE JANEIRO: CENTRO BRASILEIRO DE PESQUISAS FÍSICAS, 2002.

FERRAZ, M. N. *Uso da espectrometria para investigação da qualidade da cana-de-açúcar em campo*. 2015. 148 p. Dissertação (Mestrado em Engenharia de Sistemas Agrícolas) -

Universidade de São Paulo, Piracicaba, 2015.

FONSECA, J. J. S. Metodologia da pesquisa científica. Fortaleza: UEC, 2002. Apostila.

FRIEDMAN, Jerome; HASTIE, Trevor; TIBSHIRANI, Robert. *The elements of statistical learning*. New York, NY, USA:: Springer series in statistics, 2001.

GAMA, João et al. *Extração de conhecimento de dados: data mining*. 2015.

GIL, A. C. Como elaborar projetos de pesquisa. 4. ed. São Paulo: Atlas, 2007.

GLOBAL IMAGE THRESHOLDING USING OTSU'S METHOD. MathWorks Inc. Disponível em: <<https://www.mathworks.com/help/images/ref/graythresh.html>>. Acesso em: 17 feb. 2019.

GONZALEZ, R. C.; WOODS, R. C. *Processamento digital de imagens*. Pearson Educación, 2009.

HAYKIN, S. *Redes neurais: princípios e prática*. Porto Alegre: Bookman, 2001. 900 p.

HEMALATHA, G.; SUMATHI, C. P. Preprocessing techniques of facial image with Median and Gabor filters. In: *Information Communication and Embedded Systems (ICICES), 2016 International Conference on*. IEEE, 2016. p. 1-6. Disponível em: <<https://ieeexplore.ieee.org>>. Acesso em: 29 jul. 2018.

HUTENGS, C.; VOHLAND, M. Downscaling land surface temperatures at regional scales with random forest regression. *Remote Sensing of Environment*, v. 178, p. 127-141, 2016. Disponível em: <www.sciencedirect.com>. Acesso em: 02 ago. 2018.

IAL - INSTITUTO ADOLFO LUTZ. *Métodos físico-químicos para análise de alimentos*. São Paulo, 2008. 1020 p.

IMAGE THRESHOLDING. OpenCV. Disponível em: <https://docs.opencv.org/3.4/d7/d4d/tutorial_py_thresholding.html>. Acesso em: 17 feb. 2019.

JAMES, Gareth et al. *An introduction to statistical learning*. New York: springer, 2013.

JATMIKA, S.; PURNAMASARI, D.. Rancang Bangun Alat Pendekripsi Kematangan Buah Apel dengan Menggunakan Metode Image Processing Berdasarkan Komposisi WARNA. *Jurnal Ilmiah Teknologi Informasi Asia*, v. 8, n. 1, p. 51-58, 2014. Disponível em: <<https://jurnal.stmikasia.ac.id>>. Acesso em: 18 jul. 2018.

JHA, S. N.; KINGSLY, A. R. P.; CHOPRA, Sangeeta. Physical and mechanical properties of mango during growth and storage for determination of maturity. *Journal of Food engineering*, v. 72, n. 1, p. 73-76, 2006. Disponível em: <www.sciencedirect.com>. Acesso em: 02 jul. 2018.

JOSEPH, R. P.; SINGH, C. S.; MANIKANDAN, M. Brain tumor MRI image segmentation and detection in image processing. *International Journal of Research in Engineering and Technology*, v. 3, n. 1, p. 1-5, 2014. Disponível em: <<https://s3.amazonaws.com>>. Acesso em: 18 jul. 2018.

KAUR, A.; KRANTHI, B. V. Comparison between YCbCr color space and CIELab color space for skin color segmentation. *IJAIS*, v. 3, n. 4, p. 30-33, 2012. Disponível em: <<https://pdfs.semanticscholar.org>>. Acesso em: 29 jul. 2018.

KHAIRUNNIZA-BEJO, S.; KAMARUDIN, S. Chokanan mango sweetness determination using hsb color space. In: *Computational Intelligence, Modelling and Simulation (CIM-SiM), 2011 Third International Conference on*. IEEE, 2011. p. 216-221. Disponível em: <www.ieeexplore.ieee.org>. Acesso em: 13 jun. 2018.

MIHALOVIC, M. Performance comparison of multiple discriminant analysis and logit models in bankruptcy prediction. *Economics & Sociology*, v. 9, n. 4, p. 101, 2016. Disponível em: <<http://www.economics-sociology.eu>>. Acesso em: 17 jul. 2018.

MORPHOLOGICAL TRANSFORMATIONS. OpenCV-Python Tutorials. Disponível em: <https://opencv-python-tutorial.readthedocs.io/en/latest/py_tutorials/py_imgproc/py_morphological_ops/py_morphological_ops.html>. Acesso em: 17 jul. 2018.

2-D MEDIAN FILTERING. MathWorks Inc. Disponível em: <<https://www.mathworks.com/help/images/ref/medfilt2.html>>. Acesso em: 17 jul. 2018.

NADAFZADEH, M.; MEHDIZADEH, S. A.; SOLTANIKAZEMI, M. Development of computer vision system to predict peroxidase and polyphenol oxidase enzymes to evaluate the process of banana peel browning using genetic programming modeling. *Scientia Horticulturae*, v. 231, p. 201-209, 2018. Disponível em: <www.sciencedirect.com>. Acesso em: 27 jul. 2018.

NANDI, C. S.; TUDU, B.; KOLEY, C. A machine vision-based maturity prediction system for sorting of harvested mangoes. *IEEE Transactions on Instrumentation and measurement*, v. 63, n. 7, p. 1722-1730, 2014. Disponível em: <<https://ieeexplore.ieee.org>>. Acesso em: 12 jun. 2018.

NETO, F. P. L. Novas opções de variedades de mangueira e as vantagens competitivas. In: *Embrapa Semiárido-Artigo em anais de congresso (ALICE)*. In: *FEIRA NACIONAL DA AGRICULTURA IRRIGADA-FENAGRI*, 20., 2009. Disponível em: <www.alice.cnptia.embrapa.br>. Acesso em: 31 jul. 2018.

PAM – *Produção Agrícola Municipal*. Disponível em: <<https://sidra.ibge.gov.br/pesquisa/pam>>. Acesso em: 08 ago. 2018.

PANDEY, R.; GAMIT, N.; NAIK, S. Non-destructive quality grading of mango (*Mangifera Indica L*) based on CIELab colour model and size. In: *Advanced Communication Control and Computing Technologies (ICACCCT), 2014 International Conference on*. IEEE, 2014. p. 1246-1251. Disponível em: <[http://ieeexplore.ieee.org](https://ieeexplore.ieee.org)>. Acesso em: 27 jun. 2018.

PERMADI, Y. et al. Aplikasi Pengolahan Citra Untuk Identifikasi Kematangan Mentimun Berdasarkan Tekstur Kulit Buah Menggunakan Metode Ekstraksi Ciri Statistik. *Jurnal Informatika*, v. 9, n. 1, 2015. Disponível em: <<http://www.journal.uad.ac.id>>. Acesso em: 18 jul. 2018.

PRAVEEN, K. S. et al. Implementation Of Image Sharpening And Smoothing Using Filters. *International Journal of Scientific Engineering and Applied Science*, v. 2, n. 1, p. 7-14, 2016. Disponível em: <<http://ijseas.com>>. Acesso em: 29 jul. 2018.

RUSSELL, S. J.; NORVIG, P. *Artificial intelligence: a modern approach*. Malaysia; Pearson Education Limited,, 2016.

SALUNKHE, R., P.; PATIL, A. A. Image processing for mango ripening stage detection:

RGB and HSV method. In: *Image Information Processing (ICIIP), 2015 Third International Conference on.* IEEE, 2015. p. 362-365. Disponível em: <<https://ieeexplore.ieee.org/>>. Acesso em: 13 jun. 2018.

SCHMUTZLER, M.; HUCK, C. W. Simultaneous detection of total antioxidant capacity and total soluble solids content by Fourier transform near-infrared (FT-NIR) spectroscopy: a quick and sensitive method for on-site analyses of apples. *Food Control*, v. 66, p. 27-37, 2016.

SHAIK, K. B. et al. Comparative study of skin color detection and segmentation in HSV and YCbCr color space. *Procedia Computer Science*, v. 57, p. 41-48, 2015. Disponível em: <www.sciencedirect.com>. Acesso em: 17 jul. 2018.

SONKA, M.; HLAVAC, V.; BOYLE, R. *Image processing, analysis, and machine vision.* Cengage Learning, 2014.

SRIRAAM, N. Correlation dimension based lossless compression of EEG signals. *Biomedical Signal Processing and Control*, v. 7, n. 4, p. 379-388, 2012.

TEOH, C. C.; SYAIFUDIN, A. R. M. Image processing and analysis techniques for estimating weight of Chokanan mangoes. *Journal of Tropical Agriculture and Food Science*, v. 35, n. 1, p. 183, 2007. Disponível em: <<http://ejtafs.mardi.gov.my/jtafs/35-1/Chokanan%20mangoes.pdf>>. Acesso em: 11 jun. 2018.

VÉLEZ-RIVERA, N. et al. Computer vision system applied to classification of “Manila” mangoes during ripening process. *Food and bioprocess technology*, v. 7, n. 4, p. 1183-1194, 2014. Disponível em: <<https://link.springer.com/article/10.1007/s11947-013-1142-4>>. Acesso em: 11 jun. 2018.

YADAV, S.; JAIN, C.; CHUGH, A.. Evaluation of image deblurring techniques. *Evaluation*, v. 139, n. 12, 2016. Disponível em: <www.pdfs.semanticscholar.org>. Acesso em: 16 jul. 2018.

YAHAYA, O. K. M. et al. Determining Sala mango qualities with the use of RGB images captured by a mobile phone camera. In: *AIP Conference Proceedings*. AIP Publishing, 2015. p. 060003. Disponível em: <<http://aip.scitation.org>>. Acesso em: 27 jun. 2018.

YOSSY, E. H. et al. Mango Fruit Sortation System using Neural Network and Computer Vision. *Procedia Computer Science*, v. 116, p. 596-603, 2017. Disponível em: <www.sciencedirect.com>. Acesso em: 13 jun. 2018.

ZHENG, H.; LU, H. A least-squares support vector machine (LS-SVM) based on fractal analysis and CIELab parameters for the detection of browning degree on mango (*Mangifera indica L.*). *Computers and Electronics in Agriculture*, v. 83, p. 47-51, 2012. Disponível em: <www.sciencedirect.com>. Acesso em 12 jun. 2018.

ANEXO A – STRINGS DE BUSCA EMPREGADAS

Os dez artigos estudados foram obtidos após buscas no *Google Scholar*, onde foram utilizadas diferentes *strings*, conforme mostra a Tabela abaixo.

Tabela 8 – *Strings* de busca pesquisadas e artigos encontrados.

<i>String</i>	Artigos
<i>Mango image processing</i>	<ul style="list-style-type: none"> - <i>Image processing and analysis techniques for estimating weight of Chokanan mangoes</i> - <i>A least-squares support vector machine (LS-SVM) based on fractal analysis and CIELab paramaters for the detection of browning degree on mango (<i>Mangifera indica L.</i>)</i>
<i>Mango image processing maturity</i>	<ul style="list-style-type: none"> - <i>A machine vision-based maturity prediction system for sorting of harvested mangoes</i>
<i>Mango camera sugar content</i>	<ul style="list-style-type: none"> - <i>Chokanan mango sweetness determination using HSB color space</i>
<i>Mango classification</i>	<ul style="list-style-type: none"> - <i>Computer vision system applied to classification of “Manila” mangoes during ripening process</i>
<i>Mango HSV</i>	<ul style="list-style-type: none"> - <i>Mango Fruit Sortation System using Neural Network and Computer Vision</i>
<i>Mango RGB</i>	<ul style="list-style-type: none"> - <i>Image Processing for Mango Ripening Stage Detection: RGB and HSV method</i> - <i>Non-Destructive Quality Grading Of Mango (<i>Mangifera Indica L</i>) Based On CIELAB Colour Model and Size</i> - <i>Determination of Fruit Ripeness Degree of ‘Carabao’ Mango (<i>Mangifera indica L.</i>) using Digital Photometry</i> - <i>Determining Sala Mango Qualities with the use of RGB Images Captured by a Mobile Phone Camera</i>

Fonte: (Autor, 2019).