



**UNIVERSIDADE FEDERAL DO VALE DO SÃO
FRANCISCO**
**CURSO DE GRADUAÇÃO EM ENGENHARIA DE
COMPUTAÇÃO**

DANIELE SILVA REIS

**DETERMINAÇÃO DE ATRIBUTOS DE QUALIDADE EM
MANGAS ATRAVÉS DE PROCESSAMENTO DIGITAL DE
IMAGENS**

JUAZEIRO - BA
2019

DANIELE SILVA REIS

**DETERMINAÇÃO DE ATRIBUTOS DE QUALIDADE EM
MANGAS ATRAVÉS DE PROCESSAMENTO DIGITAL DE
IMAGENS**

Trabalho apresentado à Universidade Federal do Vale do São Francisco - UnivASF, Campus Juazeiro, como requisito da obtenção do título de Bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Rosalvo Ferreira de Oliveira Neto

Coorientador: M. Sc.^a Josenara Daiane de Souza Costa

JUAZEIRO - BA

2019

ESTA SERÁ SUA FICHA CATALOGRÁFICA

ESTA SERÁ SUA FOLHA DE APROVAÇÃO

AGRADECIMENTOS

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

RESUMO

Um dos atributos mais significativos para a garantia da qualidade de uma fruta é a quantidade de açúcares nela contida. Entretanto, para a obtenção deste valor, é exigida a destruição da amostra, de forma que seu conteúdo seja analisado. Essa abordagem, além de destrutiva, é onerosa; assim, o emprego de um sistema de visão computacional para previsão desta variável de saída mostra-se vantajoso. Entretanto, é necessário definir as variáveis visuais da fruta a partir das quais o teor de sólidos solúveis será obtido. Assim, será conduzido um estudo baseado em diferentes artigos onde é empregado o processamento de imagens para predição de atributos de qualidade. A fruta a ser analisada é a manga, das variedades ‘Tommy Atkins’ e ‘Palmer’, por ser produzida em abundância no Vale do São Francisco e por contribuir para a economia de Juazeiro (BA) e Petrolina (PE) através de sua exportação. As melhores técnicas de pré-processamento e inferência também serão avaliadas, de forma a obter a melhor abordagem para predição de sólidos solúveis em manga.

Palavras-chave: Maturação da manga. Visão computacional. *Random Forest*.

ABSTRACT

One of the most significant attributes for guaranteeing the quality of a fruit is the amount of sugars contained in it. However, to obtain this value, the destruction of the sample is required, so that its content is analyzed. This approach, besides being destructive, is onerous; thus, the use of a computer vision system to predict this output variable is advantageous. However, it's necessary to define the fruit's visual variables from which the sugar content will be obtained. Thus, a study will be conducted based on different articles in which image processing is employed to predict quality attributes. The fruit to be analyzed is the mango, from 'Tommy Atkins' and 'Palmer' varieties, due to its abundant production in the São Francisco Valley and its contribution to the economy in Juazeiro (BA) and Petrolina (PE) through exportation. The best pre-processing and inference techniques will also be evaluated in order to obtain the best approach to predict sugars in mangoes.

Key-words: *Mango ripening. Computer vision. Random Forest.*

LISTA DE ILUSTRAÇÕES

Figura 1 – Subespaço de cores RGB.	16
Figura 2 – Representação 3D do espaço de cores HSV.	17
Figura 3 – Remoção de ruído <i>salt and pepper</i> por um filtro da mediana com tamanho da janela igual a 3x3.	18
Figura 4 – Operações morfológicas realizadas na letra "j". (a) Imagem original, (b) Operação de abertura, (c) Operação de fechamento	19
Figura 5 – Aguçamento através de <i>Unsharp Masking</i>	19
Figura 6 – Estrutura de um neurônio artificial	20
Figura 7 – Etapas empregadas pelos autores.	23
Figura 8 – Imagem pré-processada e segmentada de uma manga, com suas regiões marcadas.	24
Figura 9 – Pré-processamento das imagens, extração de seus atributos e posterior construção dos modelos LS-SVM.	26
Figura 10 – Extração de atributos realizada pelos autores.	27
Figura 11 – Processo de obtenção da imagem final a partir de rotações da manga.	30
Figura 12 – Mangas da variedade Sala ⁵ em diferentes estádios de maturação.	31
Figura 13 – Câmara para aquisição das imagens.	38

LISTA DE TABELAS

Tabela 1 – Regras <i>fuzzy</i> adotadas por Pandey, Gamit e Naik (2014) para classificação de mangas quanto a seu tamanho.	33
Tabela 2 – Atributos-alvo determinados pelos autores. (Jorge interligou as colunas de SST e maturação, Acácio quer que troque “pelos autores” por “pela maturação da manga”)	34
Tabela 3 – Atributos extraídos pelos autores.	35
Tabela 4 – Técnicas de inferência utilizadas nos trabalhos estudados.	35
Tabela 5 – Métricas empregadas pelos autores.	36
Tabela 6 – <i>Strings</i> de busca pesquisadas e artigos encontrados.	44

LISTA DE ABREVIATURAS E SIGLAS

BCD	Dimensão de contagem de caixa – <i>Box Counting Dimension</i>
CCD	Dispositivo de carga acoplada – <i>Charge-coupled Device</i>
CD	Dimensão de correlação – <i>Correlation Dimension</i>
DD	Dimensão de dilatação – <i>Dilation Dimension</i>
LS-SVM	Máquina de vetores de suporte por mínimos quadrados – <i>Least-Squares Support Vector Machine</i>
MDA	Análise discriminante múltipla – <i>Multiple Discriminant Analysis</i>
MLR	Regressão linear múltipla – <i>Multiple Linear Regression</i>
PCA	Análise de componentes principais – <i>Principal Component Analysis</i>
RBF	Função de base radial – <i>Radial Basis Function</i>
RMSE	Raiz do erro quadrático médio – <i>Root Mean Square Error</i>
RFE	Eliminação recursiva de atributos - <i>Recursive Feature Elimination</i>
RNA	Rede neural artificial
RPI	<i>Ripening Index</i>
RSS	Soma do quadrado dos resíduos – <i>Residual Sum of Squares</i>
SST	Sólidos solúveis totais
SVM	Máquina de vetores de suporte – <i>Support Vector Machine</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	MOTIVAÇÃO	13
1.2	DEFINIÇÃO DO PROBLEMA	13
1.3	OBJETIVOS	13
1.3.1	Objetivo Geral	13
1.3.2	Objetivos específicos	14
1.4	ORGANIZAÇÃO DO TRABALHO	14
2	FUNDAMENTAÇÃO TEÓRICA	15
2.1	BACKGROUND	15
2.1.1	Espaços de cores	15
2.1.1.1	RGB	15
2.1.1.2	$L^*a^*b^*$	15
2.1.1.3	HSV	16
2.1.2	Pré-processamento de imagens	17
2.1.2.1	Filtro <i>deblurring</i>	17
2.1.2.2	Filtro da mediana	18
2.1.2.3	Operações de abertura e fechamento (<i>Opening and closing operations</i>)	18
2.1.2.4	Aguçamento da imagem (<i>Image sharpening</i>)	19
2.1.3	Técnicas de inferência (mantenho isso? Jorge comentou "verificar se todas as técnicas serão usadas")	19
2.1.3.1	Rede neural artificial	20
2.1.3.2	Máquina de vetores de suporte	21
2.1.3.3	Máquina de vetores de suporte por mínimos quadrados	21
2.1.3.4	Análise discriminante múltipla	21
2.1.3.5	Régressão linear múltipla	22
2.1.3.6	Sistema de inferência <i>fuzzy</i>	22
2.2	TRABALHOS RELACIONADOS	22
2.2.1	Síntese dos trabalhos estudados	34
3	MATERIAIS E MÉTODOS	37
3.1	DESCRIÇÃO DAS AMOSTRAS	37
3.2	AQUISIÇÃO DAS IMAGENS	38
3.3	OBTENÇÃO DOS VALORES DE REFERÊNCIA	39
3.4	CONSTRUÇÃO DOS MODELOS	39
3.4.1	Régressão Linear (Colocar na fundamentação?)	39
3.4.2	<i>Random Forest</i> (Colocar na fundamentação?)	40

3.5	AVALIAÇÃO DE DESEMPENHO DOS MODELOS	40
4	RESULTADOS	42
5	CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS	43
5.1	TRABALHOS FUTUROS	43
ANEXO A <i>Strings</i> de busca empregadas		44

1 INTRODUÇÃO

O Nordeste é uma das regiões de destaque na produção de manga, particularmente nas áreas irrigadas do semiárido, que apresentam boas condições para o desenvolvimento desta fruta (EMBRAPA SEMIÁRIDO, 2010). Em 2015, a região foi responsável por 70% das áreas colhidas, na qual a Bahia e Pernambuco foram os maiores contribuidores, alcançando as duas primeiras colocações na produção de manga dentre os demais estados (ANUÁRIO BRASILEIRO DE FRUTICULTURA, 2017). Na Bahia e Pernambuco, destacam-se as cidades de Juazeiro (BA) e Petrolina (PE), localizadas no Vale do São Francisco. No ano de 2016, elas foram responsáveis por quase 30% da produção nacional (PAM, 2017) e por 89% da exportação de manga no ano de 2014 (BRANCO, 2016).

Para a manutenção da demanda por mangas do Vale do São Francisco, é necessário prezar pela qualidade do produto, sendo este um fator crucial considerado pelo consumidor no momento da compra. Dentre os atributos determinantes para a qualidade da manga, destaca-se sua docura (SANTOS NETO et al., 2017). Este atributo é representado pelos sólidos solúveis totais (SST), que representam o conteúdo total de açúcares na fruta (SCHMUTZLER; HUCK, 2016). Entretanto, este atributo é normalmente obtido através de um refratômetro¹, que quantifica os SST contido no suco extraído, o que exige a destruição das amostras no processo, impossibilitando a comercialização das mesmas. Assim, surge a necessidade de determinar este atributo através de uma metodologia que não destrua as amostras.

Neste contexto, destaca-se a visão computacional, subárea da Inteligência Artificial que dá aos computadores a capacidade de aprendizado e inferência com base em informações visuais (GONZALEZ; WOODS, 2009). Em um sistema desse tipo as imagens digitais são manipuladas através de processamento de imagens, visando a extração de informações significativas sobre as mesmas. Assim, o teor de SST em mangas pode ser obtido a partir das fotos tiradas das frutas, através de um modelo preditivo que relate este teor com as informações visuais extraídas da manga. Um sistema de visão computacional, além de eliminar a necessidade da destruição das amostras, pode possibilitar a determinação do atributo desejado de forma rápida e precisa.

¹Instrumento óptico utilizado para determinar o índice de refração de uma substância (FERRAZ, 2015). Ele pode ser utilizado para monitorar a concentração de açúcar em uma solução, retornando um valor em °Brix, que corresponde a um grama de açúcar (sacarose) por 100g da solução.

1.1 MOTIVAÇÃO

O trabalho proposto possui potencial para beneficiar a comercialização da manga ao viabilizar a automatização de processos manuais. Assim, a determinação da qualidade das frutas torna-se mais rápida, econômica e consistente (DONIS-GONZÁLEZ et al., 2013). Como a obtenção do teor de sólidos solúveis não exigirá a destruição das amostras, produtoras **e/ou consumidores** de mangas não teriam mais o prejuízo do descarte, além de poderem proporcionar ao mercado consumidor um produto com qualidade assegurada.

1.2 DEFINIÇÃO DO PROBLEMA

Para a obtenção de uma informação desejada a partir de uma imagem, é necessário cumprir uma sequência de etapas que se inicia na aquisição das imagens das amostras. Segundo Esquef (2002), após a aquisição é realizado o pré-processamento das imagens. Esta etapa é fundamental em um sistema de visão computacional, sendo necessária para remover informações indesejadas, realçar ou atenuar algumas das partes da imagem. Após ser realizado o pré-processamento, é aplicada a segmentação, para que a imagem seja dividida em partes disjuntas, visando sua simplificação (JOSEPH; SINGH, 2014). No contexto deste trabalho, a única região de interesse é a manga; assim, as imagens serão segmentadas visando a separação entre a fruta e o plano de fundo. A penúltima etapa realizada é a extração de atributos, em que para cada imagem é obtido um conjunto de características que a define. Por fim, estes atributos de cada imagem são relacionados ao atributo desejado através de um modelo preditivo.

Entretanto, a escolha de técnicas de pré-processamento de imagens e atributos empregados não é realizada de forma trivial e depende da natureza do problema. Logo, para a construção de um bom modelo preditivo de sólidos solúveis totais (SST), diferentes técnicas de pré-processamento serão testadas e, para a determinação dos atributos mais significativos, um estudo investigativo sobre elas será conduzido. Por fim, a relação entre os atributos e o SST deverá ser modelada através de uma Regressão linear e Random Forest, cujos desempenhos serão avaliados através de métricas apropriadas. Assim, através deste estudo se buscará um profundo entendimento entre os aspectos visuais da manga e sua docura.

1.3 OBJETIVOS

1.3.1 Objetivo Geral

O objetivo geral do trabalho consiste na identificação de quais atributos de uma imagem da manga devem ser considerados para a predição dos sólidos solúveis.

1.3.2 Objetivos específicos

- Determinar as técnicas de pré-processamento de imagens mais adequadas para o problema;
- Realizar um estudo investigativo quanto aos atributos através de modelos de Regressão linear e Random Forest;
- Correlacionar as imagens com os atributos físico-químicos das mangas.

1.4 ORGANIZAÇÃO DO TRABALHO

O trabalho possui, além da Introdução, os capítulos de Fundamentação e Estudo Investigativo. Na fundamentação é discorrido sobre todos os tópicos necessários para o entendimento do trabalho e os artigos selecionados para o estudo. No último capítulo, é explicada a metodologia a ser aplicada, desde a coleta das mangas até a construção dos modelos preditivos, assim como o cronograma para o TCC II.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 BACKGROUND

Para um entendimento apropriado do estudo investigativo, serão discutidos aqui conceitos básicos do processamento digital de imagens, como espaços de cores, pré-processamento e técnicas de inferência para determinação de um atributo desejado.

2.1.1 Espaços de cores

Um espaço de cores é um modelo matemático utilizado para a representação de uma cor através de três ou mais componentes (SHAIK et al., 2015). Um espaço de cor pode ser orientado a um hardware específico, como o modelo RGB (*Red, Green, Blue*), para exibição em monitores coloridos ou aquisição por uma câmera digital. Entretanto, este espaço de cor não permite uma interpretação humana exata de como a cor é composta. Por outro lado, espaços de cores como o L*a*b* e HSV (*Hue, Saturation, Value*) permitem uma descrição mais natural.

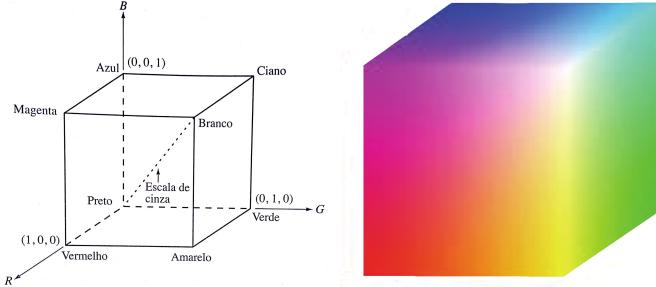
2.1.1.1 RGB

Este modelo é baseado nas três cores primárias, a partir das quais ele é nomeado: vermelho (*Red*), verde (*Green*) e azul (*Blue*). Ele é representado por um sistema de coordenadas 3D, em que cada cor é dada por um vetor que se origina na origem. Os três elementos do vetor consistem nas intensidades de cada cor primária, e assim, uma imagem RGB é representada por três matrizes, cada uma contendo as intensidades do respectivo canal (R, G, B) para todos os pixels da imagem. Quando as três cores são combinadas em suas intensidades máximas, o olho humano percebe a cor resultante como branca. Por outro lado, quando as três intensidades são nulas, tem-se a cor preta como resultante. No subespaço RGB, mostrado na Figura 1, o segmento de reta que une as cores branca e preta consiste na escala de cinza, onde as intensidades dos três canais são iguais. Os demais vértices do cubo correspondem às cores primárias e secundárias (SONKA; HLAVAC; BOYLE, 2014).

2.1.1.2 L*a*b*

Este espaço de cores, também chamado de CIE-Lab, emprega como componentes a luminosidade (L^*), que varia entre 0 (preto) e 100 (branco) e os canais “vermelho-verde” (a^*) e “amarelo-azul” (b^*). Estes últimos canais representam a variação da cor entre verde até vermelho e amarelo até azul respectivamente. A representação de uma imagem neste

Figura 1 – Subespaço de cores RGB.



(Fonte: GONZALEZ; WOODS, 2009; DATAR; JONES; SMITH JR., 2005).

sistema de cores é obtida a partir da conversão do espaço RGB para o XYZ inicialmente, através da equação (2.1):

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} 0,4125 & 0,3576 & 0,1804 \\ 0,2127 & 0,7152 & 0,0722 \\ 0,0193 & 0,1192 & 0,9502 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} \quad (2.1)$$

Após essa conversão, os valores L^* , a^* e b^* são obtidos a partir das equações (2.2), (2.3) e (2.4) (KAUR; KRAMANTHI, 2012), em que (X_b, Y_b, Z_b) é a coordenada que representa a cor branca neste espaço de cor.

$$L^* = \begin{cases} 116 * (\frac{Y}{Y_b})^{\frac{1}{3}} - 16 & \text{onde } \frac{Y}{Y_b} > 0,008856 \\ 903,3 & \text{onde } \frac{Y}{Y_b} \leq 0,008856 \end{cases} \quad (2.2)$$

$$a^* = 500 * \left[\frac{X_b^{\frac{1}{3}}}{X_b} - \frac{Y_b^{\frac{1}{3}}}{Y_b} \right] \quad (2.3)$$

$$b^* = 200 * \left[\frac{X_b^{\frac{1}{3}}}{X_b} - \frac{Z_b^{\frac{1}{3}}}{Z_b} \right] \quad (2.4)$$

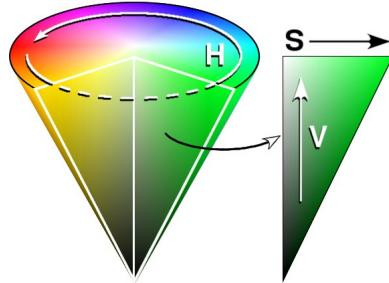
2.1.1.3 HSV

O sistema HSV, também conhecido como HSB, possui como componentes a matiz (*Hue*), saturação (*Saturation*) e valor ou brilho (*Value* ou *Brightness*), sendo capaz de descrever uma cor de uma forma mais intuitiva para os humanos (NADAFZADEH; MEHDIZADEH; SOLTANIKAZEMI, 2018).

A matiz é associada à cor dominante em uma mistura de cores, da forma como é percebida por um humano. Ela é descrita em graus, variando entre 0° e 360° , de acordo com sua localização na roda de cores, conforme a Figura 2. A saturação mede o grau de diluição de uma cor pura por luz branca, sendo estimada de acordo com a distância da cor até a origem do cone, que representa a cor branca. Por fim, o valor ou brilho indica a

quantidade de luz na combinação, sendo obtida a partir da distância da cor a partir do preto até o branco. Tanto a saturação quanto o valor/brilho possuem valores variando entre 0 e 1 (DORJ; LEE; YUN, 2017).

Figura 2 – Representação 3D do espaço de cores HSV.



Fonte: (Wikipedia, 2019).

Pode ser realizada a conversão de uma imagem no espaço de cores RGB para HSV, de forma a se obter uma melhor descrição da mesma, através das seguintes equações:

$$H = \begin{cases} \theta, & \text{se } B \leq G \\ 360 - \theta, & \text{se } B > G \end{cases} \quad (2.5)$$

$$\theta = \arccos \left\{ \frac{\frac{1}{2}[(R - G) + (R - B)]}{\sqrt{[(R - G)^2 + (R - G) * (G - B)]}} \right\} \quad (2.6)$$

$$S = 1 - \frac{3}{R + G + B} [\min(R, G, B)] \quad (2.7)$$

$$V = \frac{1}{3}(R + G + B) \quad (2.8)$$

2.1.2 Pré-processamento de imagens

A seguir estão descritas algumas das técnicas de pré-processamento mais comuns. Elas subdividem-se quanto ao domínio em que atuam, podendo ser realizadas no domínio espacial, em que as técnicas são aplicadas nos pixels diretamente, ou no domínio da frequência, em que os métodos são realizados no espectro de frequência da imagem (BEDI; KHANDELWAL, 2013).

2.1.2.1 Filtro *deblurring*

Uma imagem borrada é obtida quando a câmera que a fotografa ou o próprio objeto está em movimento. O ruído contido numa imagem borrada não é aditivo, ou seja, o pixel

não é corrompido de forma independente da vizinhança (GONZALEZ; WOODS, 2009). Assim, a imagem borrada pode ser considerada como uma versão filtrada da imagem original, sendo representada conforme a Equação 2.9.

$$g(x, y) = h(x, y) * f(x, y) + \eta(x, y) \quad (2.9)$$

Em que $g(x, y)$ corresponde à imagem borrada, $h(x, y)$ à função de degradação da imagem, $f(x, y)$ à imagem original e $\eta(x, y)$ a um ruído aditivo. O propósito da filtragem *deblurring* é “desfazer” a convolução entre a função de degradação e a imagem original, de forma a obter uma estimativa $f(x, y)$ da imagem sem borrão. Dentre as estratégias básicas de *deblurring* estão o filtro de Wiener, filtro regularizado e algoritmo de Lucy-Richardson (YADAV; JAIN; CHUGH, 2016).

2.1.2.2 Filtro da mediana

A filtragem da mediana consiste em uma operação não linear realizada no domínio espacial. Através dela o ruído de uma imagem é removido enquanto as bordas são preservadas, pois ele não é tão sensível a valores extremos. Para realizar a filtragem, move-se uma janela de tamanho predefinido pixel a pixel, de forma que cada valor seja substituído pela mediana dos valores dos pixels contidos na janela (HEMALATHA; SUMATHI, 2016). Este filtro é comumente empregado para imagens com ruído do tipo *salt and pepper*, que consiste em pixels aleatórios de cor branca ou preta, conforme mostra a Figura 3.

Figura 3 – Remoção de ruído *salt and pepper* por um filtro da mediana com tamanho da janela igual a 3x3.



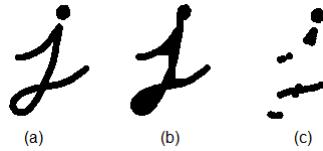
Fonte: (MathWorks Inc., 2006).

2.1.2.3 Operações de abertura e fechamento (*Opening and closing operations*)

Estas técnicas consistem em operações morfológicas baseadas nas operações de erosão e dilatação, que realiza o preenchimento de buracos nas imagens e elimina detalhes irrelevantes respectivamente. A abertura realiza a erosão seguida de dilatação, resultando na suavização do contorno de um objeto e eliminação de saliências finas. Por outro lado,

a operação de fechamento primeiro aplica a dilatação e depois a erosão, contribuindo também para a suavização do contorno do objeto e para a eliminação de pequenos buracos e preenchimento de lacunas em um contorno (ARCO et al; 2015). A Figura 4 mostra as operações de abertura e fechamento realizadas na letra “j”.

Figura 4 – Operações morfológicas realizadas na letra "j". (a) Imagem original, (b) Operação de abertura, (c) Operação de fechamento



Fonte: (Documentação OpenCV; 2018).

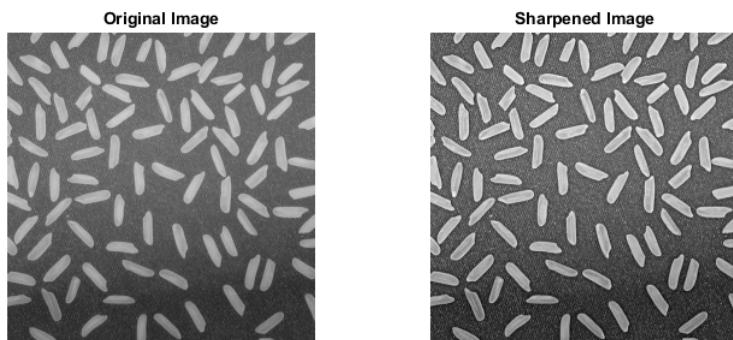
2.1.2.4 Aguçamento da imagem (*Image sharpening*)

O aguçamento é empregado visando o aumento de nitidez de uma imagem, para que as transições de intensidade sejam salientadas. Ele pode ser realizado através da diferenciação no domínio espacial, de forma que bordas e outras descontinuidades são realçadas e áreas com intensidades variando de forma suave são atenuadas. Dentre as técnicas comumente usadas há o laplaciano, gradiente e *Unsharp Masking* (PRAVEEN; 2016). A Figura 5 demonstra o aguçamento por *Unsharp Masking*.

Figura 5 – Aguçamento através de *Unsharp Masking*.

(a) Imagem original

(b) Imagem açoada



(Fonte: MathWorks Inc, 2016).

2.1.3 Técnicas de inferência (mantendo isso? Jorge comentou "verificar se todas as técnicas serão usadas")

As técnicas aqui apresentadas são empregadas para a predição de uma variável de saída desejada com base nas variáveis de entrada fornecidas, através de modelos

supervisionados de regressão ou classificação, em que a variável de saída é quantitativa ou qualitativa, respectivamente (DA SILVA; PERES; BOSCAROLI, 2017). Para tal, deve-se utilizar um conjunto de amostras de treinamento, em que as variáveis de entrada e saída são conhecidas, para a construção de um modelo matemático que extraia padrões a partir dos dados fornecidos. Assim, tendo modelado o relacionamento entre as variáveis, pode-se realizar a predição para novas amostras, em que sua variável de saída é desconhecida (GAMA, 2015).

2.1.3.1 Rede neural artificial

Uma rede neural artificial (RNA) é uma máquina projetada para modelar a maneira como um cérebro realiza uma tarefa particular (HAYKIN, 2001), e é empregada em problemas de regressão e classificação. A RNA possui uma arquitetura paralela e não linear, o que é alcançado através de neurônios artificiais (Figura 6), que simulam os neurônios reais. Os neurônios artificiais são as unidades de processamento da rede e repassam informações através das conexões entre si, semelhantemente às sinapses no cérebro humano.

Figura 6 – Estrutura de um neurônio artificial

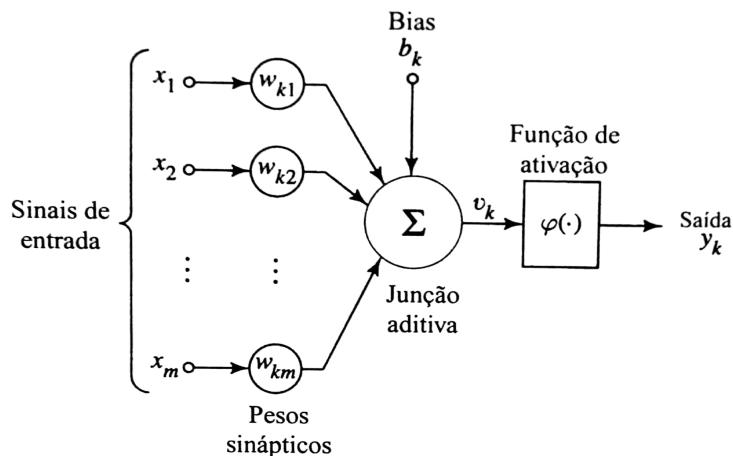


FIGURA 1.1
um neurônio

Fonte: (HAYKIN, 2001).

Os neurônios artificiais são organizados nas camadas de entrada, escondidas ou de saída. Inicialmente os dados de treinamento são fornecidos aos neurônios da camada de entrada e logo após eles são ponderados pelos pesos sinápticos dos neurônios das camadas escondidas. Nos neurônios da camada de saída, é aplicada a função de ativação sobre a soma dos dados provenientes dos neurônios da camada escondida, de forma a limitar o intervalo da amplitude da saída. Dentre as funções de ativação existentes estão disponíveis a função sigmoide, degrau, linear, entre outras.

Para a construção de uma rede neural, aplica-se um algoritmo de treinamento, onde se tenta inicialmente prever uma saída de acordo com os dados fornecidos. O erro de previsão é calculado e, a partir deste, os pesos sinápticos são ajustados. Esse processo é repetido para os dados de treinamento até que o critério de parada predefinido seja cumprido.

2.1.3.2 Máquina de vetores de suporte

A máquina de vetores de suporte (SVM, *Support Vector Machine*) é um algoritmo supervisionado utilizado para classificação. Ela constrói hiperplanos em um espaço multidimensional, buscando um hiperplano tal que haja uma melhor separação das classes, através da minimização da função objetivo por programação quadrática. A margem ótima é escolhida de acordo com sua distância até os pontos mais próximos, que se localizam nas fronteiras das classes e são chamados de vetores de suporte. Prioriza-se o hiperplano em que essa distância é a maior dentre os demais.

Uma das características mais úteis das SVMs é a possibilidade de classificação de dados que não são linearmente separáveis. Para isso são utilizadas funções *kernel*, que mapeiam os dados de entrada para um plano de dimensão maior, para que a margem seja traçada entre as classes. Existem diferentes funções *kernel*, como a linear, função de base radial (RBF, *Radial Base Function*), sigmóide e polinomial.

2.1.3.3 Máquina de vetores de suporte por mínimos quadrados

As máquinas de vetores de suporte por mínimos quadrados (LS-SVM, *Least-Squares Support Vector Machine*) são reformulações da técnica SVM. A minimização da função objetivo é feita através de sistemas lineares KKT (Karush-Kuhn-Tucker), o que exige um tempo computacional menor que a técnica predecessora, sem perda na qualidade das soluções (ABREU, 2016).

2.1.3.4 Análise discriminante múltipla

A análise discriminante é empregada quando o atributo alvo é categórico e as variáveis de entrada são quantitativas. Quando o atributo alvo possui mais de dois valores possíveis, tem-se a análise discriminante múltipla (MDA, *Multiple Discriminant Analysis*). O principal objetivo da MDA é identificar as variáveis que melhor discriminam as classes, e, para isto, são construídas funções discriminantes, que consistem em combinações lineares das variáveis de entrada. Este objetivo é alcançado através da maximização da variância entre os subgrupos de variáveis em relação à variância dentro de um mesmo grupo (MIHALOVIC, 2016).

2.1.3.5 Regressão linear múltipla

A MLR (*Multiple Linear Regression*) é um método de regressão que realiza uma combinação linear dos atributos de entrada, de forma a prever uma saída. Ela é uma extensão da linear regressão simples, possuindo a seguinte equação:

$$Y = \beta X + \epsilon \quad (2.10)$$

Em que Y é o vetor de atributo alvo, X é o vetor de atributos, β é o vetor de coeficientes da equação e ϵ é o erro aleatório. A função que melhor se ajusta aos dados é encontrada com o cálculo da soma do quadrado dos resíduos, de forma a minimizar este valor. A MLR apresenta um bom desempenho quando empregada em um conjunto de dados que não possua colinearidade entre os atributos ou ruído.

2.1.3.6 Sistema de inferência *fuzzy*

A lógica *fuzzy* foi criada para atender a necessidade de se trabalhar com informações vagas ou incertas, o que não poderia ser feito através da lógica clássica, em que as informações são representadas de forma binária. Os princípios da lógica *fuzzy* podem ser aplicados para modelar o processo de tomada de decisão humana, através da ferramenta de inferência de um sistema *fuzzy* (CAMAESTRA, 2015).

Um sistema deste tipo deve conter um conjunto *fuzzy*, que define valores linguísticos para descrever as variáveis de entrada. Após esse processo, chamado de “fuzzificação”, as variáveis podem ser utilizadas nas regras *fuzzy*, que são utilizadas pelo sistema para inferir uma saída com base nas entradas.

As regras *fuzzy* possuem o formato *if-then*, em que o antecedente da regra, localizado entre *if* e *then*, consiste em suposições dos valores das variáveis, estando combinadas pelos operadores AND e OR. O consequente da regra, situado após o *then*, define a saída que o sistema inferirá de acordo com o antecedente da regra.

2.2 TRABALHOS RELACIONADOS

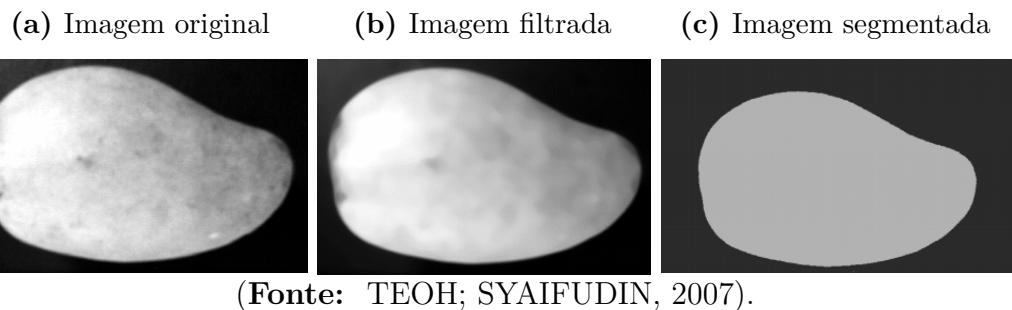
A seguir são discutidos dez artigos (*Apêndice A*) em que é empregado o processamento digital de imagens para determinação de atributos de qualidade em mangas. O estudo investigativo será conduzido de acordo com as técnicas e métricas empregadas pelos autores, assim como os atributos extraídos das imagens das mangas.

Teoh e Syaifudin (2007) propuseram em seu trabalho a determinação do peso de

mangas da variedade Chokanan² através de imagens obtidas por uma câmera digital. 100 amostras aleatórias de mangas maduras e verdes foram coletadas e divididas entre treinamento e teste (50 para cada conjunto). Os valores reais do peso das mangas foram obtidos por uma balança digital. As mangas foram inicialmente imersas em água e limpadas usando uma esponja e, após isso, foram postas em uma superfície preta e tiveram suas imagens tiradas por uma câmera de 0.3m mm/pixel de resolução, que foi situada a 22 cm acima do fruto, com uma fonte de luz de cada lado do aparelho.

Para o pré-processamento das imagens, inicialmente empregou-se o filtro da mediana de tamanho 15x15 para correção de inconsistências nas imagens devido à iluminação não uniforme. As imagens foram então segmentadas por limiarização, através da análise do histograma bimodal. A Figura 7 mostra os resultados das etapas empregadas pelos autores. A partir da imagem binária foi contado o número de pixels da região da manga, de forma que através desta variável independente o peso da respectiva manga fosse determinado. Um modelo de regressão linear foi então construído utilizando para tal 50 amostras de manga, enquanto que as demais foram empregadas para o teste do modelo, por intervalos de confiança a 95%. A abordagem proposta pelos autores mostrou-se precisa, alcançando um coeficiente de correlação igual a 97,69% e erro médio igual a 3,76%.

Figura 7 – Etapas empregadas pelos autores.



(Fonte: TEOH; SYAIFUDIN, 2007).

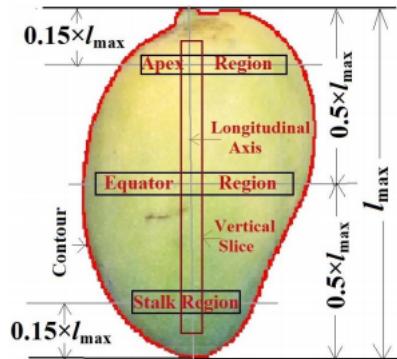
No estudo de Nandi, Tudu e Koley (2014), mangas de diferentes variedades foram separadas quanto aos dias restantes até o apodrecimento das mesmas. Foram obtidas 1350 amostras de cinco diferentes variedades e provenientes de três pomares, coletadas em três lotes com um intervalo de uma semana entre eles, sendo que em cada lote havia 90 mangas de cada variedade. As mangas foram utilizadas como entrada no sistema automatizado até o dia do apodrecimento delas, resultando em 16400 imagens. Em cada dia, três especialistas determinaram os dias restantes até a data de expiração. As imagens tiradas foram divididas em quatro grupos quanto aos dias restantes até que a respectiva manga apodrecesse (12 dias restantes, 9 até 12 dias, 5 até 8 dias e 1 até 4 dias).

²Variedade originária da Tailândia, caracterizada por frutos compridos com pontas cônicas, polpa sem fibra, pele grossa e alta resistência a doenças.

Para a classificação automática das mangas, foi desenvolvido um sistema composto por uma correia transportadora, motor, válvulas solenoides, controladora lógica, câmara de aquisição de imagens e um computador. Uma câmera com Dispositivo de Carga Acoplada (CCD, *Charge-coupled Device*) com resolução 640x480 e frame rate igual a 30 *frames/s* foi posicionada no interior da câmara, iluminada artificialmente, sendo que as imagens foram enviadas ao computador pela porta USB. As mangas eram dispostas na correia transportadora, de forma que, através de válvulas solenoides, elas fossem posicionadas no recipiente relativo à classe prevista.

Inicialmente os frames adequados foram pré-processados por um filtro *deblurring* de Wiener e filtro da mediana. Após isso, foram convertidos para uma imagem binária e as bordas foram traçadas por um algoritmo baseado em código em cadeia. As imagens das mangas foram então alinhadas em posição vertical para a posterior extração dos atributos. Os autores utilizaram apenas o espaço RGB para tal, levando em consideração o processo de maturação da manga e seu efeito nas regiões da fruta. Assim, as variáveis escolhidas foram as médias dos valores R, G e B da manga inteira e das três regiões (cume, equatorial e haste ou *apex*, *equator* e *stalk*), o gradiente dos três canais ao longo do eixo longitudinal, diferença das médias R, G e B da manga inteira e das três regiões. A Figura 8 exibe as regiões da manga consideradas para a extração de atributos.

Figura 8 – Imagem pré-processada e segmentada de uma manga, com suas regiões marcadas.



Fonte: (NANDI; TUDU; KOLEY, 2014).

O melhor subconjunto de variáveis foi obtido por eliminação recursiva de atributo (RFE) aliada à SVM, onde se obteve um *ranking* para cada variável. A SVM foi computada iterativamente, incrementando uma variável por vez, obtida a partir de uma lista decrescente de *ranking*. A classificação foi realizada por um ensemble de 7 SVMs binárias, em que cada uma realizava a separação de uma combinação diferente de 2 classes. Os parâmetros ótimos das SVMs e o melhor *kernel* foram obtidos por validação cruzada 6-fold através de uma

busca em *grid*. Após a classificação ser feita, o computador comunica-se com o controlador lógico que ativa a válvula correspondente à classe prevista e controla a velocidade da correia transportadora.

O sistema proposto pelos autores apresentou resultados satisfatórios, alcançando uma acurácia média igual a 96% ao empregar a SVM Gaussian RBF, sendo que o subconjunto de variáveis obtido pelo método RFE continha predominantemente atributos derivados do canal R.

Zheng e Lu (2012) propuseram um método para classificação de mangas quanto a seu estágio de escurecimento empregando a LS-SVM. As 90 mangas coletadas de um supermercado possuíam diferentes graus de escurecimento. Elas foram classificadas visualmente por um perito em três diferentes classes: fresca sem escurecimento, escurecimento moderado e escurecimento severo. Foram então tiradas três imagens de cada manga através de uma câmera digital Canon EOS 50 D, sob iluminação solar. Antes da extração dos atributos, cada imagem foi pré-processada através da sua subtração pelo fundo.

Os atributos extraídos foram os valores médios dos canais L*, a*, b*, e as dimensões fractais dos frutos, que consistem em descritores geométricos das imagens. Estas foram calculadas por três diferentes técnicas: dimensão de contagem de caixa (BCD, *Box Counting Dimension*), dimensão de correlação (CD, *Correlation Dimension*) e dimensão de dilatação (DD, *Dilation Dimension*).

Na técnica BCD, o espaço euclidiano que contém a imagem é dividido em um *grid* de caixas de tamanho r, que, ao ser diminuído progressivamente, resulta em diferentes quantidades de caixas não vazias, dada por $N(r)$. O valor da variável BCD é então dado por:

$$BCD = \lim_{r \rightarrow 0} \frac{\log N(r)}{\log (1/r)} \quad (2.11)$$

De forma semelhante, na variável DD cada pixel da borda da imagem é substituído por um círculo de diâmetro r que aumenta progressivamente, resultando em diferentes valores para o comprimento de borda $L(r)$ de cada círculo. Assim, o valor DD é encontrado através da Equação 2.12.

$$DD = \lim_{r \rightarrow 0} \frac{\log L(r)}{\log (1/r)} \quad (2.12)$$

Por fim, CD é uma medida de dimensionalidade, calculada através da 2.13:

$$CD = \lim_{r \rightarrow 0} \frac{\log C(r)}{\log (1/r)} \quad (2.13)$$

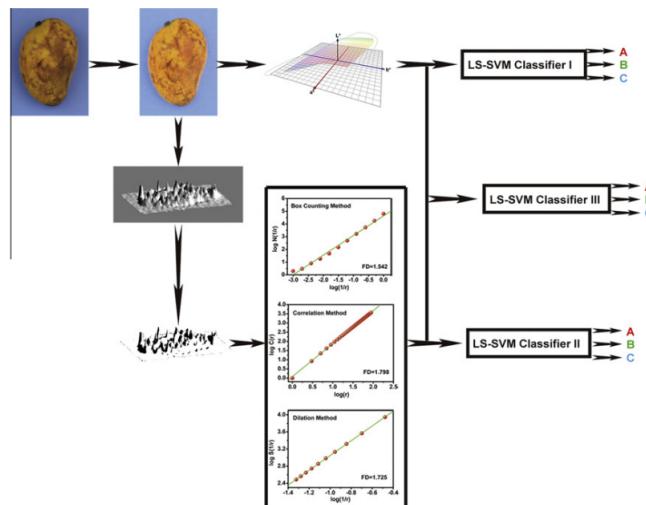
Em que $C(r)$ é dada por:

$$C(r) = \lim_{n \rightarrow \infty} \frac{1}{N^2} \sum_{j=1}^N \sum_{i=j+1}^N \theta(r - \|R_i - R_j\|) \quad (2.14)$$

Em que r é uma distância limiar, N é o número de pontos, θ é a função de *Heaviside* e R representa os pontos.

Assim, três diferentes modelos LS-SVM foram computados: um que utiliza apenas as variáveis de cor, outro para as variáveis fractais e o terceiro para todas as variáveis. A Figura 9 exibe as etapas realizadas pelos autores, desde o pré-processamento até a construção dos modelos.

Figura 9 – Pré-processamento das imagens, extração de seus atributos e posterior construção dos modelos LS-SVM.



Fonte: (ZHENG; LU, 2012).

Os parâmetros ótimos da LS-SVM foram obtidos por uma busca em *grid* aliada à validação cruzada *full*. 70% das amostras foram escolhidas aleatoriamente para o treinamento da LS-SVM e as demais para o teste, resultando em uma acurácia igual a 100% para o modelo com todas as variáveis. Por outro lado, o modelo que emprega apenas as variáveis $L^*a^*b^*$ e o que utiliza as variáveis fractais obtiveram acuráncias iguais a 88,89% e 85,19% respectivamente.

No trabalho de Khairunniza-Bejo e Kamarudin (2011), determinou-se a docura de mangas Chokanan² com o emprego do espaço de cores HSB (ou HSV). O lote colhido pelos autores continha mangas em seis diferentes estádios de maturação. Os valores de SST foram obtidos através de um refratômetro digital em um ambiente a 24,6 °C. As

imagens foram tiradas por uma câmera CCD a 40 cm de distância da manga, em uma sala com iluminação apropriada, resultando em 180 imagens tiradas.

O valor médio dos pixels no espaço HSB foi obtido para cada imagem, conforme mostra a Figura 10. Cada variável foi empregada para um modelo de regressão linear separadamente, de forma que fosse determinado o melhor canal para determinação de SST em mangas Chokanan².

Figura 10 – Extração de atributos realizada pelos autores.



Fonte: (KHAIRUNNIZA-BEJO; KAMARUDIN, 2011).

A faixa de valores de SST foi dividida em três índices ($4,0^{\circ}$ - $8,0^{\circ}$, $8,0^{\circ}$ - $13,0^{\circ}$ e $13,0^{\circ}$ - $17,0^{\circ}$), de forma que a regressão fosse aplicada em cada faixa separadamente. Ademais, os nove modelos construídos utilizaram 50% das imagens enquanto que as demais foram empregadas para o teste.

A melhor variável obtida foi a matiz, que alcançou uma correlação de Pearson igual a -0,92, enquanto que a saturação e brilho alcançaram coeficientes iguais a 0,85 e 0,66 respectivamente. A matiz apresentou também o menor desvio padrão para os três índices (2,73, 6,31 e 2,44), enquanto que o desvio padrão para o brilho indicou que os valores dos pontos eram bastante dispersos (35,15, 18,09 e 22,79 nos índices 1, 2 e 3 respectivamente). O modelo que emprega matiz apresentou os menores valores para erro médio quadrático no índice 2 e 3 (0,22 e 0,03 °Brix respectivamente) e a maior Raiz do erro quadrático médio (RMSE, *Root Mean Square Error*) para o índice 1 (0,06 °Brix). Os modelos com saturação apresentaram os maiores RMSE nos índices 1 e 3, enquanto que o modelo com brilho foi superior no índice 1. Como a diferença entre os erros foi pequena, considerou-se que a matiz provou ser a melhor variável para determinação de SST em mangas, devido ao melhor valor de correlação de Pearson.

Yossy et al. (2017) propôs um sistema de classificação de mangas quanto ao estádio de maturação e tamanho com o emprego de redes neurais. 52 mangas da variedade Gincu³ foram empregadas para o treinamento do modelo. Elas possuíam dois tamanhos diferentes (grande e pequeno) e dois estádios diferentes (verde e madura), assim, as classes definidas pelos autores foram grande-madura, pequena-madura, grande-verde e grande-pequena. As imagens foram tiradas através de uma *webcam* a 30 cm de distância e armazenadas como JPEG.

Duas abordagens de pré-processamento foram empregadas a partir da imagem RGB: na primeira, o espaço de cores RGB foi convertido para HSV e as faixas dos valores H, S e V foram determinadas para a etapa posterior de transformação dos pixels em um *array*. Em seguida, foram aplicadas operações de abertura e fechamento visando a eliminação de objetos e buracos pequenos respectivamente. Por fim, a imagem foi redimensionada para 16x16 pixels visando a redução de tempo computacional. Na segunda abordagem, a partir da imagem RGB obteve-se a imagem em escala de cinza, que foi limiarizada para a obtenção do contorno da manga. Tendo obtido o contorno, um retângulo foi desenhado ao redor dele. A partir deste retângulo foram obtidas sua largura e altura, que representam o tamanho do objeto de forma simbólica. As duas medidas foram convertidas para centímetro. Os pixels da imagem 16x16 foram representados em um *array* de 257 posições, sendo que os 256 primeiros valores correspondiam às cores dos pixels da imagem (1 - verde, 2 - vermelho, 3 - laranja e 0 para outra cor) e a última posição do *array* conteve o tamanho da respectiva manga (6 – grande e 7 - pequena). Este *array* foi então utilizado como entrada da rede neural, que possuía função de ativação sigmoide e treinamento por *back propagation*. O treinamento foi realizado para as 52 amostras com diferentes taxas de aprendizado (0,000001 e 0,0001) e número de camadas escondidas (5, 20, 25, 40, 50, 60, 75, 80, 100).

Os autores obtiveram como melhor resultado uma acurácia igual a 94% ao empregar 40 camadas escondidas e taxa de aprendizado igual a 0,0001, alcançando um tempo de treinamento igual a 4 segundos. Entretanto, a escolha de camadas escondidas é questionável, pois é introduzida no modelo uma quantidade de parâmetros livres maior do que de atributos de entrada. Apesar disto os autores obtiveram bons resultados, o que pode indicar um *overfitting* do modelo, visto que não foi mencionado o emprego de um conjunto de teste.

O resultado obtido pelos autores foi ligeiramente inferior ao obtido por Jatmika e Purnamasari (2014), que alcançaram uma acurácia igual a 100% na classificação de mangas

³A variedade Gedong Gincu é uma das mais populares da Indonésia, lugar de onde se originou. Ela possui um tamanho médio, com seu comprimento entre 10 e 12cm, e peso entre 200 e 250g. Além disso, ela tem um formato arredondado, cor alaranjada e sabor adocicado.

quanto ao estádio de maturação, mas maior que o obtido por Permadi et al. (2015), que obteve uma acurácia igual a 75% na discriminação dos estádios de maturação do pepino.

No estudo de Vélez-Rivera et al. (2014), estimou-se o estádio de maturação de mangas da variedade Manila⁴ empregando como atributos sólidos solúveis, acidez, firmeza, índice RPI (*Ripening Index*) e média dos pixels nos espaços de cores L*a*b* e HSB, totalizando dez variáveis de entrada. Foram obtidos dois lotes de um mercado, sendo que o primeiro, contendo 117 amostras, foi utilizado para treinamento do modelo, enquanto que o segundo lote com 39 mangas foi empregado para a checagem da robustez do modelo. As mangas coletadas possuíam diferentes estádios de maturação, formato e tamanho, mas todas possuíam a superfície sem defeito. Elas foram limpas por uma solução com 1% de NaOCl por dez minutos, lavadas com água destilada e secas em temperatura ambiente. As amostras foram armazenadas no escuro a 25 °C e 75% de umidade relativa por 13 dias em uma câmara. Em cada dia 9 mangas eram coletadas para a aquisição de imagens e obtenção de parâmetros físico-químicos.

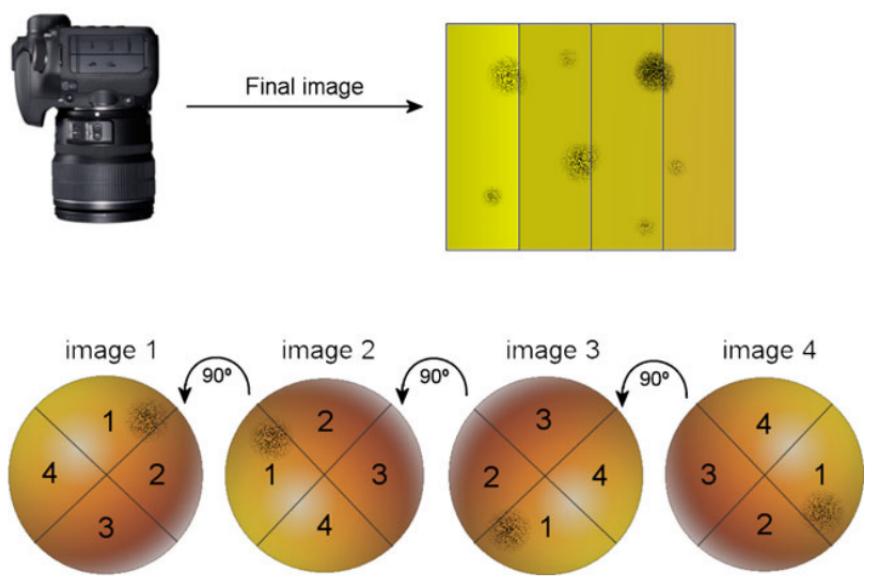
Foi utilizada uma lâmpada fluorescente circular de 32 W para a iluminação, com a imagem tirada por uma câmera Rebel XS W18-55Is de 24 MP, capturada com 3888x2592 pixels no formato JPEG e armazenadas como TIFF. Foram tiradas quatro fotos das mangas inteiras, sendo que elas foram rotacionadas em 90° a cada foto, conforme mostra a Figura 11. De cada imagem extraiu-se a faixa central ao longo do comprimento da manga, e assim, a imagem final foi composta pelas quatro faixas.

De cada imagem foram obtidos os atributos referentes aos espaços de cores L*a*b* e HSV. A respectiva manga teve então sua polpa removida visando a obtenção dos valores de SST através de um refratômetro digital, enquanto que a acidez foi obtida por uma titulação com 0,1 NaOH e a firmeza por um teste de penetração. O índice de maturação RPI foi calculado a partir dos valores obtidos anteriormente de SST, acidez e firmeza.

Após a obtenção dos atributos, empregou-se PCA (Análise de componentes principais – *Principal Component Analysis*) para a determinação das variáveis mais significativas e MDA com intervalo de confiança a 95% para a classificação. Com as dez variáveis empregadas, obteve-se uma variância explicada igual a 93,71%, com 76,65% para PC1 e 17,06% para PC2. Notou-se também pela PCA que as variáveis menos significativas foram L* e B e, sem elas, obteve-se uma variância explicada igual a 95,18%, com 90,10% para PC1 e 5,08% para PC2. Assim, a MDA foi aplicada para as oito variáveis restantes, resultando em 100% de acurácia na determinação do estádio de maturação das mangas do lote de teste. Ao remover as variáveis físico-químicas, obteve-se uma acurácia média

⁴Variedade nativa das Filipinas caracterizada por um formato semielíptico, cor levemente verde que amarela conforme a maturação. Sua textura é suave, suculenta e pouco fibrosa e é conhecida por ser muito doce quando está madura.

Figura 11 – Processo de obtenção da imagem final a partir de rotações da manga.



Fonte: (VÉLEZ-RIVERA et al., 2014).

igual a 84,62% e, com apenas a*, b*, H e S, obteve-se 84,62%. Já era esperada uma alta acurácia para o modelo que empregou as variáveis físico-químicas, pois estas consistem em informações a posteriori, ou seja, são determinadas a partir do estádio de maturação das mangas, o que as torna inadequadas para o treinamento do modelo. Além disso, a opção de empregar estas variáveis deturpa o princípio da não destruição das amostras, que consiste na maior vantagem do emprego de processamento digital de imagens para a determinação de atributos de qualidade em frutas.

Yahaya et al. (2015) determinaram os atributos de SST, acidez e firmeza em mangas através de imagens capturadas por um smartphone. Foram coletadas manualmente 57 mangas da variedade Sala⁵ e armazenadas a 16 °C e umidade em 50%. As amostras coletadas estavam em diferentes estádios de maturação, com sua superfície possuindo uma cor uniforme, conforme mostra a Figura 12. As frutas foram iluminadas pela tela de um smartphone *Samsung Galaxy Note 1* e tiveram suas fotos tiradas pela câmera frontal do mesmo, de 8 MP.

Para a determinação dos valores de referência, empregou-se inicialmente um penetrômetro na manga intacta para a obtenção dos valores de firmeza. A manga foi então cortada em cubos e batida num liquidificador para a obtenção do suco. Por fim, usou-se um

⁵As mangas da variedade Sala, originárias da Malásia, são frutas azedas, com comprimento entre 12 a 15 cm e um formato não arredondado. Elas são consumidas preferencialmente quando ainda estão verdes ou quase maduras. Saiba mais em: <http://dahasry.blogspot.com/2011/02/harumanis-vs-sala.html>.

Figura 12 – Mangas da variedade Sala⁵ em diferentes estádios de maturação.



Fonte: (YAHAYA, 2015).

refratômetro e pHmetro para obtenção do SST e pH a partir do suco. Os valores médios de R, G e B foram obtidos para o treinamento de um modelo de regressão por MLR.

O modelo calibrado para determinação de firmeza possuiu um coeficiente de correlação igual a 0,875 e RMSE igual a 1,392 kgf, enquanto que para o SST e acidez obteve-se 0,814 e 0,913 como coeficiente de correlação respectivamente e 1,218 °Brix e 0,166 pH como RMSE. Ao utilizar o modelo para prever os atributos em amostras não utilizadas no treinamento, foram obtidos coeficientes de correlação iguais a 0,913, 0,814 e 0,875 para a firmeza, SST e acidez respectivamente.

No trabalho de Salunkhe e Patil (2015), determinaram-se os estádios de maturação de mangas Alphonso⁶ com base nos espaços de cores RGB e HSV. As frutas foram coletadas frescas e verdes para análise primária, sendo que os testes foram realizados ao longo do ciclo de maturação delas. Após a aquisição das imagens, foi realizada a segmentação da manga através de uma ferramenta pronta, a custo de uma precisão reduzida. Os valores médios das matrizes R, G e B foram obtidos e, a partir destes, as razões R/G e R/B. As imagens foram então convertidas para o espaço de cores HSV, e a razão S/H foi obtida.

Dentre as mangas colhidas, 80 foram classificadas manualmente, com 20 mangas para cada estádio, de forma que foram obtidos limiares (R/G, R/B, S/H) que separassem

⁶É uma das variedades mais caras do mundo, majoritariamente cultivada na Índia. Ela é conhecida por sua riqueza de sabor, textura suave e polpa delicada, tornando-a uma das variedades mais procuradas. Sua superfície é amarelada com uma leve coloração vermelha no topo. Saiba mais em: [https://en.wikipedia.org/wiki/Alphonso_\(mango\)](https://en.wikipedia.org/wiki/Alphonso_(mango)).

as classes. A partir das faixas de limiares obtidos, foi desenvolvido um algoritmo para classificação das mangas, através de comandos *if-else*.

Para o teste do algoritmo, foram empregados três conjuntos de 24 mangas em diferentes estádios. Para o modelo com RGB e HSV, respectivamente, obteve-se uma acurácia de 90,4% e 84,2%, taxas de falso positivos iguais a 2,57% e 7,9%, verdadeiros positivos iguais a 89,77% e 86,74%. As razões RGB aumentaram conforme o progresso da maturação, mas com diferentes taxas. A cor azul possuiu o menor peso nas imagens, verde possuiu o maior peso em mangas verdes e o vermelho possuiu o maior peso em mangas completamente maduras.

Pandey, Gamit e Naik (2014) classificaram mangas quanto à sua saúde e tamanho. As mangas coletadas eram das variedades Totapuri⁷, Badami⁸ e Neelam⁹, sendo que elas diferiam quanto ao formato e tamanho. Dentre as 100 colhidas, 60 eram saudáveis e 40 possuíam uma das três seguintes doenças: antracose, putrefação por bactéria e putrefação na haste. As imagens das mangas foram coletadas por uma câmera digital Nikon DLSR D90, que foi posicionada no topo de uma câmara que também continha uma lâmpada CFL 14 W. A câmera estava conectada a um computador, de forma que as imagens foram transferidas para um cartão de memória. As imagens obtidas possuíam 640x480 pixels.

As imagens obtidas foram convertidas para escala de cinza, tiveram seu tamanho reduzido e foram pré-processados por filtro da mediana visando a redução de ruído. Como o filtro da mediana contribuiu para que as bordas das mangas fossem suavizadas, foi necessário aguçá-las. As imagens então foram segmentadas e passadas para o espaço de cores L*a*b*, em que b* foi utilizado para determinar o limiar entre mangas saudáveis e doentes, sendo que as três doenças analisadas possuíam como sintoma a cor amarronzada/preta das mangas. Para cada fruta, foi estimada a razão de pixels marrons/pretos em relação à área da manga (dada pela soma dos valores da imagem binária resultante da segmentação), e dependendo deste valor, a manga foi classificada como saudável ou doente. Tendo determinado quais mangas eram saudáveis, estas foram classificadas quanto à categoria (medíocre, média e excelente), de acordo com a área e diâmetro, sendo este calculado por meio da área. Um sistema de inferência *fuzzy* foi desenvolvido para determinar a classe da manga a partir de 9 regras *if-then*, utilizando como entradas a área e o diâmetro, conforme a Tabela 1.

Fonte – (PANDEY; GAMIT; NAIK, 2014).

⁷Variedade cultivada em sua maior parte na Índia e Sri Lanka, possuindo uma cor amarela esverdeada.

⁸As mangas Badami são douradas em sua superfície, possuem uma polpa sem fibras e um aroma floral, com um sabor semelhante às da manga Alphonso⁶.

⁹As mangas desta variedade são originárias da Índia e possuem uma aparência uniforme, cor dourada e um aroma característico. Saiba mais em: <http://www.sunrisenaturals.in/products/13/neelam-mango-pulp.php>.

Tabela 1 – Regras *fuzzy* adotadas por Pandey, Gamit e Naik (2014) para classificação de mangas quanto a seu tamanho.

Área/Diâmetro	Pequeno	Médio	Grande
Pequena	Qualidade medíocre	Qualidade medíocre	Qualidade medíocre
Média	Qualidade medíocre	Qualidade média	Qualidade média
Grande	Qualidade medíocre	Qualidade média	Qualidade grande

Com o sistema de inferência *fuzzy*, os autores obtiveram uma acurácia média igual a 93,33% na classificação quanto à saúde da manga e 91,41% na classificação da categoria dela.

Abarra et al. (2018) determinaram atributos físico-químicos de mangas através dos espaços de cores RGB, L*a*b* e HSV, sendo eles acidez titulável, açúcares totais, amido total, firmeza, acidez, SST e total de açúcares reduzido. 18 mangas da variedade Carabao¹⁰ foram coletadas quando estavam totalmente verdes e sem mancha alguma, com seu armazenamento feito em caixas de papelão a 18 °C e 92% de umidade relativa. Um conjunto de três mangas foi separado para que suas imagens fossem tiradas em cada estádio de maturação, que foi determinado de forma visual. Foram definidos seis estádios, que foram representados por um índice de cor (1- completamente verde, 2 - quebra de cor, 3 - mais verde que amarelo, 4 - mais amarelo que verde, 5 - amarelo com resquícios de verde e 6 - completamente amarelo). Um conjunto de três mangas foi separado para cada estádio de maturação para que as análises destrutivas fossem realizadas. Alguns dos atributos físico-químicos desejados, como acidez titulável, açúcares totais e amido total foram obtidos quimicamente, enquanto que a firmeza, acidez, SST e total de açúcares reduzido foram determinados por um penetrômetro, phmetro, refratômetro e espectrofotômetro respectivamente.

As mangas foram colocadas em uma caixa de madeira compensada, cujo interior possuía dois LEDs brancos e um buraco para a inserção da câmera digital de 14,1 MP (GE E1450W). Duas fotos foram tiradas para cada manga, uma para cada lado da mesma, e então os atributos foram extraídos de cada imagem, sendo eles os valores médios de R, G, B, L*, a*, b*, H, S e V. As funções para determinação destes atributos foram formuladas como combinações de um, dois ou três canais de cores. Os valores calculados por essa função foram plotados versus os valores de referência, para avaliação do coeficiente de correlação.

Os autores notaram que os melhores resultados obtidos foram aqueles que em-

¹⁰Também conhecida como manga Manila⁴.

pregaram o espaço de cores RGB para determinação da acidez titulável e firmeza, não informando os resultados obtidos para os demais atributos físico-químicos. Assim, para a acidez, obtiveram-se os coeficientes 0,917, 0,948, 0,915 e 0,977 para R, G, B e L* respectivamente e 0,924 e 0,948 para R+G e R+G+B. Para a firmeza, os coeficientes de correlação obtidos foram 0,899, 0,941, 0,933 e 0,968 para R, G, B e L* respectivamente e 0,906 e 0,948 para R+G e R+G+B. Os resultados obtidos para firmeza foram ligeiramente inferiores aos encontrados por Domingo et al. (2013), que determinou a firmeza em mamões, alcançando os coeficientes de correlação 0,9387 e 0,9497 para as funções binária e ternária em RGB, respectivamente.

2.2.1 Síntese dos trabalhos estudados

A seguir são sumarizadas as variáveis de entrada e saída, técnicas e métricas empregadas pelos autores.

Tabela 2 – Atributos-alvo determinados pelos autores. (Jorge interligou as colunas de SST e maturação, Acácio quer que troque “pelos autores” por “pela maturação da manga”)

Autores/Atributos-alvo	Peso	Maturação	Apodrecimento	Tamanho	SST	Acidez	Firmeza	Doença
Teoh e Syaifudin (2007)	X							
Nandi, Tudu e Koley (2014)			X					
Zheng e Lu (2012)			X					
Khairunniza-Bejo e Kamarudin (2011)					X			
Yossy (2017)	X			X				
Vélez-Rivera (2014)	X							
Yahaya (2015)					X	X	X	
Salunkhe (2015)	X							
Pandey (2014)				X				X
Abarra (2018)					X	X	X	

Fonte – (Autor, 2019).

Nota-se que na maioria dos artigos é feita a classificação ao invés da regressão, devido ao fato de os atributos qualitativos previstos serem facilmente determinados através de uma inspeção visual. Isto é comprovado pelos bons resultados encontrados pelos autores, enquanto que nos artigos em que o atributo alvo é quantitativo, as métricas obtidas foram inferiores.

Fonte – (Autor, 2019).

O pré-processamento das imagens foi realizado em poucos trabalhos, visto que na maioria deles a aquisição das imagens foi realizada sob boas condições. Neste estudo

Tabela 3 – Atributos extraídos pelos autores.

Autores/Atributos	Média RGB	Diferença de médias e gradiente RGB	Taxas R/G, R/B e S/H	Média HSV	Canal HSV dominante	Média L*a*b*	Número de pixels	Variáveis fractais	Diâmetro
Teoh e Syaifudin (2007)							X		
Nandi, Tudu e Koley (2014)		X							
Zheng e Lu (2012)						X		X	
Khairunniza-Bejo e Kamarudin (2011)					X				
Yossy (2017)						X			
Vélez-Rivera (2014)				X			X		
Yahaya (2015)	X								
Salunkhe (2015)	X			X	X				
Pandey (2014)						X	X		X
Abarra (2018)	X			X		X			

investigativo essas quatro técnicas serão testadas, para verificação se há uma melhora na capacidade preditiva do modelo.

Percebe-se uma grande variedade de atributos empregados pelos autores, mas com uma predominância dos valores médios dos pixels nos diferentes espaços de cores. O sistema HSV foi o mais empregado por se aproximar mais da percepção de cores do ser humano.

Tabela 4 – Técnicas de inferência utilizadas nos trabalhos estudados.

Autores/Técnicas	Regressão linear	MLR	SVM	LS-SVM	Rede neural	MDA	Sistema fuzzy	Regras de produção
Teoh e Syaifudin (2007)	X							
Nandi, Tudu e Koley (2014)			X					
Zheng e Lu (2012)				X				
Khairunniza-Bejo e Kamarudin (2011)		X						
Yossy (2017)					X			
Vélez-Rivera (2014)						X		
Yahaya (2015)		X						
Salunkhe (2015)								X
Pandey (2014)							X	
Abarra (2018)		X						

Fonte – (Autor, 2019).

Para os problemas de classificação, é visível o emprego de diferentes técnicas para a predição de atributos. Por outro lado, os autores que realizaram regressão em seus trabalhos optaram por técnicas menos sofisticadas, a Regressão linear e MLR, supondo uma relação linear entre as variáveis de entrada e saída.

As métricas empregadas pelos autores serão também empregadas neste estudo investigativo, para comparação direta com os resultados obtidos por eles.

Fonte – (Autor, 2019).

Tabela 5 – Métricas empregadas pelos autores.

Autores/Atributos-alvo	Coefficiente de correlação	RMSE	Acurácia	Taxa de falsos positivos e verdadeiros positivos
Nandi, Tudu e Koley (2014)		X		
Zheng e Lu (2012)		X		
Khairunniza-Bejo e Kamarudin (2011)				
Yossy (2017)		X		
Vélez-Rivera (2014)		X		
Yahaya (2015)	X	X		
Salunkhe (2015)			X	
Pandey (2014)		X		X
Abarra (2018)	X			

3 MATERIAIS E MÉTODOS

Design do método! (Marconi, Gil, Cervo) c/ diagrama

Dentre os dez artigos estudados, o atributo SST foi determinado em apenas três deles. O melhor resultado foi obtido para um modelo simplificado de regressão linear, em que as mangas foram divididas em três classes de acordo com o nível de SST, enquanto que para os demais modelos os resultados foram medianos ou ruins ao empregar no máximo três variáveis de entrada. Assim, nota-se uma carência de um modelo robusto e generalista para predição de SST. Desta forma, o estudo será conduzido de forma a investigar quais atributos visuais da manga mais se relacionam a esse atributo de qualidade, para que um bom modelo preditivo seja obtido.

Os atributos a serem extraídos das imagens das mangas serão todos aqueles empregados nos dez artigos, listados na Tabela 3. Estes atributos, juntamente dos valores reais de SST para cada manga, serão utilizados para a construção de modelos preditivos. As técnicas de inferência empregadas serão a Regressão linear e *Random Forest*. Através da Regressão linear será verificada se há uma relação linear entre cada variável de entrada e a de saída, assim como foi realizado pelos autores que determinaram SST em seus trabalhos. Ademais, na técnica Random Forest todas as variáveis de entrada serão utilizadas em um mesmo modelo, e por meio deste serão determinadas as variáveis mais significativas para a predição de SST em mangas.

3.1 DESCRIÇÃO DAS AMOSTRAS

As mangas a serem utilizadas no estudo são das variedades ‘Palmer’ e ‘Tommy Atkins’, sendo duas das variedades mais produzidas no Vale do São Francisco (EMBRAPA SEMIÁRIDO, 2010). A variedade Palmer é caracterizada por frutos aromáticos e grandes, com peso de até 900 g, tom esverdeado ou arroxeados quando estão imaturos e cor vermelha quando maduros. Por outro lado, os frutos da variedade Tommy Atkins possuem um peso de aproximadamente 500 g e possuem uma coloração alaranjada, amarelada, avermelhada ou púrpura (NETO, 2009).

As amostras serão coletadas de pomares comerciais da Fazenda SpecialFruit Importação e Exportação Ltda. em Petrolina e Juazeiro. Serão marcadas trinta plantas distribuídas em cinco fileiras de plantio de um lote do pomar. A cada quinze dias serão colhidos manualmente 60 frutos (dois de cada planta), para cada variedade, iniciando-se dos 35 dias após a floração até o ponto de colheita comercial adotado pela Fazenda. **As mangas ficarão armazenadas para a aquisição das imagens também na pós-colheita. (Como se deu essa parceria?)**

3.2 AQUISIÇÃO DAS IMAGENS

As imagens das mangas serão obtidas para cada lado da fruta, que serão colocadas em uma caixa de madeira compensada com um orifício no topo (Figura 13), onde será posicionada uma câmera de 18 MP. O interior da caixa é preto fosco e contém uma superfície não reflexiva para o apoio das mangas. Na parte superior serão dispostos 3 LEDs brancos para a iluminação das amostras. (Origem do equipamento)

Figura 13 – Câmara para aquisição das imagens.



Fonte: (Autor, 2019).

Foram tiradas fotos de 1080 mangas, sendo destas 480 da variedade ‘Tommy Atkins’ e 600 da ‘Palmer’. Os dois lados de cada amostra foram fotografados, de forma que no total obtiveram-se 2160 imagens.

A aquisição foi realizada de 15 em 15 dias para cada variedade, de forma que fossem obtidas imagens das mangas em diferentes estádios de maturação. Para a variedade ‘Tommy Atkins’, foram fotografadas 60 amostras por vez nas 7 primeiras coletas e 30 amostras nas 2 coletas subsequentes. A aquisição para a variedade ‘Palmer’ iniciou-se 1 semana após a da ‘Tommy Atkins’, com 60 amostras sendo fotografadas por vez em 8

coletas e 30 amostras em 4 coletas subsequentes. A Figura 13 exibe uma foto tirada para cada variedade.

3.3 OBTENÇÃO DOS VALORES DE REFERÊNCIA

Os valores reais de SST serão obtidos segundo o procedimento do Instituto Adolfo Lutz (2008), sendo também adotado por Yahaya et al. (2015). Nele, as mangas têm inicialmente sua polpa homogeneizada e filtrada por uma centrífuga. O suco extraído é colocado em um refratômetro digital (HI 96804, Hanna Instruments, USA) para a quantificação de SST em °Brix.

3.4 CONSTRUÇÃO DOS MODELOS

3.4.1 Regressão Linear (Colocar na fundamentação?)

A regressão linear consiste em uma técnica estatística utilizada para prever uma variável quantitativa com base em uma única variável de entrada. Ela é empregada quando o relacionamento entre x e y é presumidamente linear (JAMES et al., 2013), como mostra a Equação 3.1:

$$Y = \beta_0 + \beta_1 X + \epsilon \quad (3.1)$$

Em que Y é o vetor de variável de saída, X é o vetor de variável de entrada, β_0 e β_1 são o intercepto e inclinação da reta respectivamente e ϵ é o erro aleatório.

Para que a estimativa da variável de saída seja realizada, os parâmetros β_0 e β_1 devem inicialmente ser estimados, o que é feito normalmente pelo método de mínimos quadrados. Neste critério, busca-se minimizar a soma do quadrado dos resíduos (*RSS – Residual Sum of Squares*), dada pela equação abaixo:

$$RSS = e_1^2 + e_2^2 + \dots + e_n^2 \quad (3.2)$$

Em que $e_1^2, e_2^2, \dots, e_n^2$ correspondem à diferença entre o valor previsto pelo modelo e o valor real para as n amostras. Dada a função a ser minimizada, as expressões de β_0 e β_1 são dadas por:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (3.3)$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x} \quad (3.4)$$

Em que x corresponde ao valor da variável de entrada, \bar{x} é a média dos valores de x , y é o valor da variável de saída e \bar{y} é a média dos valores de y .

3.4.2 **Random Forest (Colocar na fundamentação?)**

A *Random Forest* consiste em uma técnica *ensemble* não linear, em que uma variável qualitativa ou quantitativa é determinada através de uma combinação de modelos de árvores de decisão (FRIEDMAN; HASTIE; TIBSHIRANI, 2001). A relação entre as variáveis de entrada e a de saída é modelada através de um conjunto de regras de decisão, construídas por divisões binárias e recursivas dos dados de treinamento. Cada regra de decisão utiliza uma única variável de entrada para a divisão dos dados, sendo ela selecionada a partir de um subconjunto aleatório de todas as variáveis. Um modelo de regressão é então construído a partir das variáveis selecionadas e o erro RSS é calculado (HUTENGS; VOHLAND, 2016). As regras de decisão e consequentemente as variáveis de entrada, são selecionadas visando a minimização desse erro. Assim, a *Random Forest* permite a determinação das variáveis mais significativas para a predição da variável de saída.

O valor previsto resultante será a média dos resultados obtidos para cada árvore de decisão. Para evitar a correlação entre as árvores, elas são construídas a partir de subconjuntos não disjuntos dos dados de entrada, o que torna o modelo resultante mais estável, robusto e preciso (BREIMAN, 2001).

3.5 AVALIAÇÃO DE DESEMPENHO DOS MODELOS

Para a avaliação da capacidade preditiva dos modelos, será utilizada a estratégia de validação cruzada *k-fold* (*k-fold cross validation*). Ela é empregada para assegurar que não há um sobreajuste (*overfitting*) no modelo, através da divisão do conjunto de dados em *k* subconjuntos disjuntos, com uma alocação das amostras para o conjunto de treinamento ou teste (DA SILVA; PERES; BOSCAROLI, 2017). Assim, um dos subconjuntos será utilizado como teste e os *k-1* demais para o treinamento, de forma que o modelo realize a predição para dados desconhecidos. Este procedimento é repetido *k* vezes, alterando os subconjuntos a cada vez.

As predições resultantes serão avaliadas através de um teste de hipóteses e das métricas de correlação e RMSE, empregadas nos artigos em que a regressão foi realizada. Estes indicadores medem, respectivamente, o grau de dependência entre as variáveis de entrada e saída e a magnitude média dos erros estimados (ALVES; VECCHIA, 2011), conforme as equações abaixo:

$$R = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (3.5)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.6)$$

Em que x_i é o valor da variável de entrada, \bar{x} é a média dos valores de x , y_i é o valor real da variável de saída, \bar{y} é a média dos valores de y , n é o número de amostras e \hat{y}_i é o valor previsto para a variável de saída.

4 RESULTADOS

5 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS

5.1 TRABALHOS FUTUROS

ANEXO A – STRINGS DE BUSCA EMPREGADAS

Os dez artigos estudados foram obtidos após buscas no *Google Scholar*, onde foram utilizadas diferentes *strings*, conforme mostra a Tabela abaixo.

Tabela 6 – *Strings* de busca pesquisadas e artigos encontrados.

<i>String</i>	Artigos
<i>Mango image processing</i>	<ul style="list-style-type: none"> - <i>Image processing and analysis techniques for estimating weight of Chokanan mangoes</i> - <i>A least-squares support vector machine (LS-SVM) based on fractal analysis and CIELab paramaters for the detection of browning degree on mango (<i>Mangifera indica L.</i>)</i>
<i>Mango image processing maturity</i>	<ul style="list-style-type: none"> - <i>A machine vision-based maturity prediction system for sorting of harvested mangoes</i>
<i>Mango camera sugar content</i>	<ul style="list-style-type: none"> - <i>Chokanan mango sweetness determination using HSB color space</i>
<i>Mango classification</i>	<ul style="list-style-type: none"> - <i>Computer vision system applied to classification of “Manila” mangoes during ripening process</i>
<i>Mango HSV</i>	<ul style="list-style-type: none"> - <i>Mango Fruit Sortation System using Neural Network and Computer Vision</i>
<i>Mango RGB</i>	<ul style="list-style-type: none"> - <i>Image Processing for Mango Ripening Stage Detection: RGB and HSV method</i> - <i>Non-Destructive Quality Grading Of Mango (<i>Mangifera Indica L</i>) Based On CIELAB Colour Model and Size</i> - <i>Determination of Fruit Ripeness Degree of ‘Carabao’ Mango (<i>Mangifera indica L.</i>) using Digital Photometry</i> - <i>Determining Sala Mango Qualities with the use of RGB Images Captured by a Mobile Phone Camera</i>

Fonte – (Autor, 2019).